PROJET 4

Analyse des données de vente et retours

Livrable 1 : phases du projet et planification Scrum

Product Owner : Yacine Lezoul

Scrum Master : Achraf Chihab

Développeurs : Jean Robert Joseph, Barnabe Landry Evouna, Douyeri Lamoussa Sanogo, Mouncif Bouchachi

Collège La Cité · Science des données appliquées
Remise : 5 octobre 2026

Équipe

Rôle	Membre
Product Owner	Yacine Lezoul
Scrum Master	Achraf Chihab
Développeur	Jean Robert Joseph
Développeur	Barnabe Landry Evouna
Développeur	Douyeri Lamoussa Sanogo
Développeur	Mouncif Bouchachi

Dans la suite du document, les membres sont désignés par leur prénom usuel : Yacine, Achraf, Jean Robert, Barnabé, Lamoussa et Mouncif.

Vision produit

Optimiser la performance commerciale en identifiant les drivers de vente, les facteurs de retour et l'impact réel des promotions, mesurés en **marge brute en valeur** (et non en taux), afin de proposer des recommandations opérationnelles chiffrées.

Le projet couvre les quatre niveaux d'analyse : **descriptive** (que s'est-il passé ?), **diagnostique** (pourquoi ?), **prédictive** (que va-t-il se passer ?) et **prescriptive** (que faut-il faire ?). Le volet prescriptif simule des scénarios de promotion et détermine la politique de remise qui maximise la marge en valeur nette des retours.

Le jeu de données fourni ne contient que la table des transactions (2020-2021), sans aucune table de dimension. Le Sprint 0 a donc inclus une phase de **collecte et recherche de données**, décrite ci-dessous.

Collecte des données : démarche et résultats

1. Identification de la source

La structure des fichiers fournis (IdVente, IdBoutique, IdProduit, IdPromotion, montants de vente, de retour et de remise) est identique à la table **FactSales** de la base publique **Contoso Retail DW** de Microsoft, à deux colonnes près (canal et devise).

2. Collecte

- Téléchargement de la base (ContosoBIdemoBAK, Microsoft Download Center)
- Restauration du fichier `.bak` dans **SQL Server Express** avec SSMS
- Connexion depuis Python (pyodbc, SQLAlchemy) et extraction de chaque table dans son propre CSV ; les colonnes géographiques (type `geography`) sont converties en texte

3. Vérification

- Les IdVente d'un échantillon de nos fichiers ont été retrouvés dans FactSales avec **les mêmes boutiques, produits, quantités, remises et montants** : **IdVente = SalesKey**
- Les dates sont **décalées de 12 ans** : 2008-2009 dans Contoso correspondent à 2020-2021 dans nos données
- Exemple : la promotion 10 est la « European Holiday Promotion » (remise saisonnière de 20 %), active du 1er octobre 2019 au 31 janvier 2020 une fois les dates réalignées
- Règles métier observées : Montant des ventes = Prix unitaire × Quantité − Remise ; une vente peut porter une promotion sans remise, et la remise ne s'applique qu'à une partie des unités

4. Arborescence des clés étrangères

Les relations déclarées dans la base (`sys.foreign_keys`) donnent le chemin de jointure complet à partir des ventes, y compris les doubles jointures :

```
FactSales ─┬─ StoreKey     → DimStore   → DimGeography
           ├─ ProductKey   → DimProduct → DimProductSubcategory → DimProductCategory
           ├─ PromotionKey → DimPromotion
           ├─ DateKey      → DimDate
           ├─ channelKey   → DimChannel
           └─ CurrencyKey  → DimCurrency
```

5. Sélection des tables : 8 retenues sur 17

Une table n'est utile que si elle se relie à nos ventes (directement ou par double jointure) **et** aide à répondre à une question de recherche.

Table	Décision	Lien avec nos ventes	Questions servies
DimStore	Retenue	IdBoutique	Q1 (type, surface, effectif, ouverture), Q3
DimGeography	Retenue	Double jointure via DimStore	Q1 (analyse géographique)
DimProduct	Retenue	IdProduit	Q1, Q3, Q5 (marque, classe, prix catalogue)
DimProductSubcategory	Retenue	Double jointure via DimProduct	Q1, Q3, Q5
DimProductCategory	Retenue	Triple jointure via DimProduct	Q1, Q3, Q5
DimPromotion	Retenue	IdPromotion	Q2, Q4, Q5 (type, % de remise, dates)
DimChannel	Retenue	Canal récupéré depuis FactSales (IdVente = SalesKey)	Q1 : 3 canaux présents dans nos ventes (48 %, 30 % et 21 % des lignes)
DimCurrency	Écartée	Devise récupérée depuis FactSales	Une seule devise dans nos ventes : aucune information utile

Table	Décision	Lien avec nos ventes	Questions servies
DimDate	Référence	Dates 2007-2009	Remplacée par notre propre calendrier 2020-2021 (fériés, COVID-19)
DimCustomer	Écartée	Aucun lien avec FactSales (liée aux ventes en ligne)	
DimAccount, DimEntity, DimScenario	Écartées	Comptabilité et budget (FactStrategyPlan)	
DimEmployee, DimMachine, DimOutage, DimSalesTerritory	Écartées	Aucun lien avec FactSales	

6. Inventaire et homogénéisation des ventes (notebook 00_inventaire)

Les 6 fichiers de ventes ont été chargés, homogénéisés et contrôlés sans modifier les données brutes :

Contrôle	Résultat
Fichiers	6 fichiers, chacun conforme au trimestre annoncé par son nom
Trimestres absents	2020 T4 et 2021 T4 (octobre à décembre des deux années)
Ventes	144 874 lignes, du 1er janvier 2020 au 30 septembre 2021
Homogénéisation des formats	Encodage UTF-8 et 14 colonnes identiques dans les 6 fichiers ; dates au format mois/jour/année ; montants texte (« $1,062.60 ») convertis en nombres ; aucun échec de conversion
Doublons	Aucun IdVente en double
Correspondance des clés	100 % pour les boutiques (56), les produits (1 310), les promotions (12) et les ventes (IdVente = SalesKey)
Décalage de 12 ans	98,66 % des ventes en promotion tombent dans la période de leur promotion avec un décalage de 12 ans, contre 0 à 1,6 % pour les autres décalages
Canal et devise	3 canaux, 1 seule devise

Résultats détaillés : `reports/livrables/L1_L2_phases_backlog/dictionnaire_donnees.xlsx` et `reports/figures/00_ca_mensuel.png`.

7. Données de contexte (à collecter)

Jours fériés 2020-2021 et périodes de confinement COVID-19 pour les pays des boutiques.

Calendrier général

Projet sur **7 sprints** (1 à 2 semaines), démarrage **lundi 21 septembre 2026**. Les sprints sont calés sur les dates de remise communiquées par le professeur : chaque remise tombe un lundi, le sprint se termine donc le dimanche précédent.

Sprint	Thème	Dates	Sprint Review / Rétro	Livrable remis
0	Cadrage, collecte et recherche de données	21 sept.-4 oct. 2026	ven. 2 oct.	L1 et L2 + présentation UA1 (lun. 5 oct.)
1	ETL, consolidation et modèle en flocon	5-18 oct. 2026*	ven. 16 oct.	

Sprint	Thème	Dates	Sprint Review / Rétro	Livrable remis
2	Diagnostic de qualité et nettoyage	19 oct.-1 nov. 2026	ven. 30 oct.	
3	Transformation et rapport de diagnostic	2-8 nov. 2026	ven. 6 nov.	L3 (lun. 9 nov.)
4	Analyse Q1 à Q4, modèle prédictif des retours, tableau de bord Excel	9-22 nov. 2026	ven. 20 nov.	
5	Q5, modèles prédictifs, simulation et optimisation des remises, Power BI, rapport et présentation	23 nov.-6 déc. 2026	ven. 4 déc.	L4 (lun. 7 déc.)
6	Analyse de sensibilité, plan promotionnel et rapport final	7-13 déc. 2026	ven. 11 déc.	L5 (lun. 14 déc.)

*Le 12 octobre 2026 est l'Action de grâce (jour férié) : le Sprint Planning du sprint 1 a lieu le lundi 5 octobre, pas d'impact sur la date de fin.

Livrables et pondération

Livrable	Contenu	Date de remise	Poids
L1	Identification des phases du projet	5 oct. 2026	20 % (avec L2)
L2	Création de tâches granulaires (ce backlog)	5 oct. 2026	
L3	Diagnostic, nettoyage et transformation des données	9 nov. 2026	25 %
L4	Analyse exploratoire, rapport et présentation des conclusions	7 déc. 2026	35 %
L5	Rapport final avec recommandations opérationnelles	14 déc. 2026	20 %

Rythme des cérémonies Scrum

- **Lundi (début de sprint)** : Sprint Planning (45-60 min) : sélection des user stories, découpage en tâches, estimation, répartition
- **Mardi à jeudi** : Daily standup (15 min) : fait / à faire / blocages
- **Sprints de 2 semaines** : point de mi-sprint le lundi de la 2e semaine (20 min) pour réajuster la charge
- **Vendredi (fin de sprint)** :
  - Sprint Review (30-45 min) : démonstration des résultats au Product Owner
  - Rétrospective (30 min) : ce qui a bien marché / ce qui peut être amélioré / actions pour le sprint suivant
- **Week-end avant remise** : marge de sécurité pour la relecture et la mise en forme du livrable

Definition of Done (générale)

- Code versionné (Git) et documenté, revu par un autre membre
- Résultats reproductibles (le pipeline s'exécute de bout en bout à partir des fichiers bruts)
- Hypothèses et limites documentées
- Résultat validé par le PO en Sprint Review
- Livrable présentable (graphique, tableau, tableau de bord ou synthèse écrite)
-

Outils

- Gestion du backlog : Jira / GitHub Projects (backlog détaillé de 166 tâches dans le fichier Excel joint)
- Code, ETL, analyse et modélisation : Python (pandas, numpy, matplotlib, seaborn, plotly, scipy, statsmodels, scikit-learn, shap, pytest), notebooks Jupyter
- Orchestration et versionnement : papermill, Git / GitHub, nbstripout
- Extraction des données : SQL Server Express, SSMS, pyodbc, SQLAlchemy
- Optimisation : Python (scipy.optimize, PuLP) et Solveur Excel
- Tableaux de bord et simulation : Excel (Power Query, tableaux croisés dynamiques, segments, Gestionnaire de scénarios) et Power BI (modèle en flocon, DAX, paramètre what-if)
- Présentations : PowerPoint
- Rapports : Word

Architecture du projet et pipeline d'exécution

Principe : les **données** (`data/`, lourdes, non versionnées), le **code** (`notebooks/`, `src/`, `tests/`, versionnés sur GitHub) et les **livrables** (`dashboards/`, `reports/`) sont séparés. Les données passent par quatre états : brut, transformé, validé, résultats.

```
Projet ADD/
│
├── README.md                          # présentation du projet, installation, exécution
├── requirements.txt                   # bibliothèques Python et leurs versions
├── .gitignore                         # ce que GitHub ignore : data/, notebooks/executes/
├── Connexion.py                       # extraction SQL Server → data/raw/contoso
├── run_pipeline.py                    # lance tous les notebooks dans l'ordre
│
├── data/                              # LES DONNÉES
│   ├── raw/                           # 1. BRUT : jamais modifié
│   │   ├── contoso/
│   │   │   ├── Dim/                   # tables de dimension extraites de Contoso
│   │   │   └── Sales/                 # ventes fournies + clés canal et devise
│   │   └── contexte/                  # jours fériés, périodes COVID-19
│   │
│   ├── interim/                       # 2. TRANSFORMÉ : pas encore nettoyé
│   │   ├── ventes_consolidees.parquet # toutes les ventes, montants en nombres
│   │   ├── dimensions_realignees/     # dates des dimensions décalées de +12 ans
│   │   ├── dim_date.parquet           # notre calendrier 2020-2021
│   │   └── ventes_jointes.parquet     # ventes + toutes les dimensions
│   │
│   ├── clean/                         # 3. VALIDÉ : prêt pour l'analyse
│   │   ├── fait_ventes.parquet        # ventes avec anomalies traitées
│   │   ├── dimensions/                # dimensions vérifiées
│   │   ├── journal_nettoyage.csv      # ce qui a été corrigé, et pourquoi
│   │   ├── rapport_validation.csv     # résultat des contrôles de qualité
│   │   └── agregats/                  # totaux par semaine, boutique, produit, promotion
│   │
│   └── outputs/                       # 4. RÉSULTATS : lus par Power BI et Excel
│       ├── predictions/               # prévision des ventes, risque de retour
│       ├── scenarios/                 # résultats des simulations
│       └── optimisation/              # remise optimale, plan promotionnel
│
├── notebooks/                         # LE CODE, étape par étape
│   ├── 1_preparation/
│   │   ├── 00_inventaire.ipynb        # vérifier les fichiers et les clés
│   │   ├── 01_etl.ipynb               # raw → interim : regrouper, convertir
│   │   ├── 02_flocon.ipynb            # réaligner les dates, joindre les dimensions
│   │   ├── 03_diagnostic.ipynb        # repérer les anomalies
│   │   ├── 04_nettoyage.ipynb         # interim → clean : corriger, valider
│   │   └── 05_variables.ipynb         # marge, taux de retour, taux de remise
│   ├── 2_analyses/
│   │   ├── 06_q1_performance.ipynb    # facteurs de performance des ventes
│   │   ├── 07_q2_promotions.ipynb     # effet des promotions
│   │   ├── 08_q3_q4_retours.ipynb     # retours et lien avec les remises
│   │   └── 09_q5_remises.ipynb        # marge selon le niveau de remise
│   ├── 3_modeles/
│   │   ├── 10_risque_retour.ipynb     # prédire les ventes retournées
│   │   ├── 11_reponse_promo.ipynb     # prédire l'effet d'une remise
│   │   └── 12_prevision.ipynb         # prévoir les ventes hebdomadaires
│   ├── 4_prescriptif/
│   │   ├── 13_simulation.ipynb        # comparer des scénarios de remise
│   │   ├── 14_optimisation.ipynb      # trouver la remise optimale
│   │   └── 15_plan_promo.ipynb        # tester la solidité, bâtir le plan
│   └── executes/                      # copies exécutées (preuve que tout tourne)
│
├── src/                               # FONCTIONS RÉUTILISÉES par les notebooks
│   ├── config.py                      # chemins des dossiers, décalage de 12 ans
│   ├── etl.py                         # charger, convertir, joindre
│   ├── qualite.py                     # contrôles et règles de nettoyage
│   ├── features.py                    # calcul des indicateurs
│   ├── modeles.py                     # entraîner et évaluer les modèles
│   ├── prescriptif.py                 # simuler et optimiser
│   └── viz.py                         # charte graphique : couleurs, police, format des montants
│
├── tests/                             # VÉRIFICATIONS AUTOMATIQUES
│   ├── test_etl.py                    # montants bien convertis, aucune vente perdue
│   ├── test_qualite.py                # ventes = prix × quantité − remise
│   ├── test_features.py               # taux entre 0 et 1, marge correcte
│   └── test_prescriptif.py            # remise, budget et retours dans les limites
│
├── dashboards/                        # TABLEAUX DE BORD
│   ├── excel/
│   │   ├── tableau_de_bord.xlsx       # indicateurs, graphiques, segments
│   │   └── optimisation_solveur.xlsx  # optimisation refaite avec le Solveur
│   └── powerbi/
│       └── projet4.pbix               # lit data/clean et data/outputs
│
└── reports/                           # LIVRABLES
    ├── figures/                       # graphiques exportés des notebooks
```

```
    ├── livrables/
    │   ├── L1_L2_phases_backlog/
    │   ├── L3_diagnostic_nettoyage/
    │   ├── L4_analyse/
    │   └── L5_rapport_final/
    └── presentations/
        ├── UA1_cadrage.pptx
        └── finale_conclusions.pptx
```

Notebooks : contenu, flux des données et responsables

Notebook	Contenu	Lit dans	Écrit dans	Sprint	Responsable
Connexion.py	Extraction des tables Contoso	SQL Server	raw/contoso	0	Yacine
00_inventaire	Vérifier les fichiers et la correspondance des clés sur toutes les lignes	raw	reports/figures	0	Jean Robert
01_etl	Regrouper les ventes, convertir les montants	raw	interim	1	Jean Robert
02_flocon	Réaligner les dates (+12 ans), construire le calendrier, joindre les dimensions	raw, interim	interim	1	Mouncif
03_diagnostic	Repérer les anomalies (manquants, incohérences, valeurs aberrantes)	interim	reports/figures	2	Barnabé
04_nettoyage	Appliquer les règles, écrire le journal, valider	interim	clean	2	Mouncif
05_variables	Marge en valeur, taux de retour, taux de remise, agrégats	clean	clean/agregats	3	Lamoussa
06_q1_performance	Q1 : facteurs de performance des ventes	clean	reports/figures	4	Jean Robert et Barnabé
07_q2_promotions	Q2 : effet des promotions	clean	reports/figures	4	Lamoussa
08_q3_q4_retours	Q3 et Q4 : retours et lien avec les remises	clean	reports/figures	4	Mouncif
09_q5_remises	Q5 : marge selon le niveau de remise	clean	reports/figures	5	Barnabé
10_risque_retour	Prédire les ventes retournées	clean	outputs/predictions	4	Jean Robert
11_reponse_promo	Prédire l'effet d'une remise	clean	outputs/predictions	5	Barnabé
12_prevision	Prévoir les ventes hebdomadaires	clean/agregats	outputs/predictions	5	Lamoussa
13_simulation	Comparer des scénarios de remise	clean, outputs/predictions	outputs/scenarios	5	Jean Robert
14_optimisation	Trouver la remise optimale sous contraintes	outputs/predictions	outputs/optimisation	5	Jean Robert
15_plan_promo	Tester la solidité, bâtir le plan promotionnel	outputs	outputs/optimisation	6	Jean Robert et Lamoussa
Excel, Power BI	Tableaux de bord et page what-if	clean, outputs	dashboards	4-5	Barnabé (Excel), Mouncif (Power BI)

Exécution

`python run_pipeline.py` lance tous les notebooks avec papermill dans l'ordre des dépendances. Les étapes indépendantes s'exécutent en parallèle, et une copie exécutée de chaque notebook est archivée dans `notebooks/executes/`.

Étape	Notebooks	Mode
1. Préparation	00 → 01 → 02 → 03 → 04 → 05	Séquentiel (chaque étape dépend de la précédente)
2. Analyses	06, 07, 08, 09	En parallèle
3. Modèles	10, 11, 12	En parallèle

Étape	Notebooks	Mode
4. Prescriptif	13 → 14 → 15	Séquentiel

Tests automatiques (pytest)

Les tests sont lancés avant toute écriture dans `clean` ou `outputs` : une étape n'écrit ses résultats que si ses contrôles passent.

Fichier	Vérifications
test_etl.py	« $1,062.60 » converti en 1062.60 ; aucune vente perdue à la jointure ; dates décalées de 12 ans
test_qualite.py	Montant des ventes = Prix × Quantité − Remise ; retours ≤ ventes ; quantité remisée ≤ quantité vendue
test_features.py	Taux de retour et de remise entre 0 et 1 ; marge = ventes − coût
test_prescriptif.py	Remise optimale entre 0 et 30 % ; budget de remise respecté ; taux de retour ≤ seuil ; le scénario actuel reproduit la situation observée

Conventions

- Les données de `raw` ne sont jamais modifiées : chaque étape lit le dossier précédent et écrit dans le suivant (raw → interim → clean → outputs), ce qui permet de relancer une étape sans refaire les précédentes.
- Tous les chemins viennent de `src/config.py`, jamais écrits en dur dans les notebooks.
- Un notebook par responsable pour éviter les conflits Git ; le code réutilisable va dans `src/` plutôt que d'être copié entre notebooks.
- Les sorties des notebooks sont retirées avant chaque commit (nbstripout) ; `data/` est partagé par OneDrive ou Teams, pas par GitHub.

Épopées

ID	Épopée	Objectif
E0	Gestion de projet Scrum	Organiser l'équipe, planifier et suivre les sprints
E1	Collecte et recherche de données	Inventorier les données, identifier les manques, collecter les dimensions et le contexte
E2	Intégration et modélisation (ETL)	Consolider les trimestres, construire un modèle en flocon
E3	Qualité et nettoyage	Diagnostiquer et corriger les anomalies
E4	Transformation et variables dérivées	Créer les indicateurs de marge, de retour et de remise
E5	Analyse exploratoire (Q1 à Q5)	Répondre aux questions de recherche
E6	Modélisation prédictive	Prévoir les ventes, le risque de retour et la réponse aux promotions
E7	Tableaux de bord	Explorer d'autres modes de visualisation (Excel, Power BI)
E8	Documentation et livrables	Rapports, présentations et remises
E9	Analyse prescriptive	Simuler des scénarios de promotion et déterminer la politique de remise optimale

Backlog produit (priorisé)

#	User story	Épopée	Sprint	Priorité	Points
US01	Cadre Scrum et espace de travail commun (board, dépôt Git, DoD)	E0	0	Must	3
US02	Inventaire et homogénéisation des données fournies (6 trimestres, dictionnaire initial)	E1	0	Must	3
US03	Identification des données manquantes et de leur impact, demande au professeur	E1	0	Must	2
US04	Collecte et vérification des tables de dimension (Contoso Retail DW), arborescence des clés, sélection des tables	E1	0	Must	8
US05	Collecte des données de contexte (jours fériés, périodes COVID-19)	E1	0	Should	3
US06	Phases et jalons du projet (Livrable 1)	E0	0	Must	2
US07	Backlog de tâches granulaires, estimées et priorisées (Livrable 2)	E0	0	Must	5
US08	Présentation PowerPoint du cadrage (UA1)	E8	0	Must	3
US09	Table de faits unique consolidant les 6 trimestres	E2	1	Must	5
US10	Modèle en flocon (faits ventes + boutique → géographie, produit → sous-catégorie → catégorie, promotion, date, canal)	E2	1	Must	8
US11	Pipeline reproductible exécutable en une commande (run_pipeline.py)	E2	1	Must	5
US12	Diagnostic complet de la qualité des données	E3	2	Must	8
US13	Nettoyage selon des règles documentées et testées	E3	2	Must	5
US14	Variables dérivées : marge en valeur, taux de retour, taux de remise	E4	3	Must	5
US15	Jeux agrégés prêts pour l'analyse et les tableaux de bord	E4	3	Must	3
US16	Rapport de diagnostic, nettoyage et transformation (Livrable 3)	E8	3	Must	5
US17	Q1 : facteurs déterminants de la performance des ventes	E5	4	Must	8
US18	Q2 : effet des promotions sur le volume et la marge en valeur	E5	4	Must	8
US19	Q3 : patterns de retour de produits	E5	4	Must	5
US20	Tableau de bord Excel interactif	E7	4	Should	5
US21	Q4 : corrélation entre remises et taux de retour	E5	4	Must	5
US22	Q5 : niveaux de remise qui maximisent la marge en valeur	E5	5	Must	5

#	User story	Épopée	Sprint	Priorité	Points
US23	Modèle de prévision des ventes	E6	5	Must	8
US24	Tableau de bord Power BI multi-pages	E7	5	Must	8
US25	Rapport d'analyse et présentation des conclusions (Livrable 4)	E8	5	Must	8
US26	Rapport final avec recommandations opérationnelles (Livrable 5)	E8	6	Must	5
US28	Modèle prédictif du risque de retour et de ses facteurs (Q3, Q4)	E6	4	Must	5
US29	Modèle de réponse aux promotions : volume et marge attendus selon la remise (Q2, Q5)	E6	5	Must	8
US30	Simulation de scénarios de promotion (what-if)	E9	5	Must	5
US31	Optimisation du taux de remise par catégorie sous contraintes (Q5)	E9	5	Must	8
US32	Analyse de sensibilité et plan promotionnel recommandé	E9	6	Must	5
US33	Structure du dépôt, notebooks numérotés et conventions communes	E2	0	Must	3
US27	Cérémonies Scrum à chaque sprint	E0	Tous	Must	3

Total : 33 user stories, 175 points, 166 tâches, environ 280 heures d'équipe.

Sprint 0 : Cadrage, collecte et recherche de données (21 sept.-4 oct.)

Objectif : cadrer le projet, combler le manque de données de dimension et remettre les livrables 1 et 2. *(Cadrage)*

- **Yacine (PO)** : rédige la vision produit, reformule les questions de recherche, envoie la demande au professeur sur les tables de dimension, définit les phases et jalons (L1), priorise le backlog
- **Achraf (SM)** : met en place le board Scrum (Jira / GitHub Projects), construit le diagramme de Gantt, saisit le backlog, anime le kick-off et rédige la Definition of Done
- **Jean Robert** : crée le dépôt Git, l'arborescence, les squelettes des 16 notebooks et l'environnement (requirements.txt, nbstripout), charge les 6 fichiers trimestriels et relève volumétrie, types et période couverte
- **Barnabé** : inventorie les données manquantes (boutique, produit, promotion, client, retours, stocks, charges) et évalue leur impact sur Q1 à Q5, rédige le dictionnaire de données initial
- **Lamoussa** : mesure le taux de correspondance des clés sur toutes les lignes des fichiers de ventes, évalue FactInventory (stocks) pour la démarque
- **Mouncif** : collecte les jours fériés et les périodes de confinement COVID-19 par pays, vérifie la cohérence des dates, documente les sources et conditions d'utilisation
- **Toute l'équipe** : présentation PowerPoint UA1 (contexte, données et manques, démarche de collecte, arborescence des clés et sélection des tables, phases, backlog et sprints), une partie par membre, répétition chronométrée

État d'avancement (28 sept.) : base Contoso restaurée et extraite (`Connexion.py`), source vérifiée (FactSales, décalage de 12 ans confirmé sur toutes les ventes), arborescence des clés établie, 8 tables retenues, environnement de travail en place (`.venv`, `requirements.txt`, `config.py`, `.gitignore`, README), charte graphique commune (`viz.py`), inventaire et homogénéisation des 6 fichiers de ventes terminés (00_inventaire), dictionnaire de données produit. Reste : données de contexte (reportées au sprint 1), Gantt, board Scrum, présentation UA1.

Sprint 1 : ETL, consolidation et modèle en flocon (5-18 oct.)

Objectif : disposer d'une base unique, fiable et exploitable par Python, Excel et Power BI. *(Préparation)*

- **Jean Robert** : script de chargement, harmonisation des colonnes, types et formats de date, concaténation des trimestres, factorisation du code partagé dans `src/`, script `run_pipeline.py` (papermill) testé sur un poste vierge
- **Barnabé** : contrôle des doublons d'IdVente entre trimestres, réconciliation des lignes et des totaux avant et après consolidation
- **Lamoussa** : construction de la dimension date (jour, semaine, mois, trimestre, jour férié, période COVID), aplatissement des hiérarchies produit et géographie
- **Mouncif** : conception du schéma en flocon, réalignement des dates des dimensions (+12 ans), jointure des dimensions et du canal, traitement des clés sans correspondance (membre « Inconnu »), export Parquet et CSV dans data/interim
- **Yacine (PO)** : valide le modèle de données et le seuil de correspondance des clés acceptable

Sprint 2 : Diagnostic de qualité et nettoyage (19 oct.-1 nov.)

Objectif : identifier toutes les anomalies et les traiter selon des règles validées. *(Analyse descriptive)*

- **Jean Robert** : taux de valeurs manquantes, valeurs nulles ou négatives, valeurs aberrantes (IQR, z-score) et leur visualisation
- **Barnabé** : contrôles arithmétiques (Montant des ventes = Prix unitaire × Quantité − Remise, Coût total = Coût unitaire × Quantité), comparaison avec les prix et coûts de DimProduct

- **Lamoussa** : contrôles de cohérence (retours ≤ ventes, quantité de remise ≤ quantité vendue, promotion sans remise, ventes hors dates de promotion ou de fonctionnement des boutiques), synthèse chiffrée des anomalies
- **Mouncif** : application des règles de nettoyage dans le pipeline (data/interim → data/clean), journal avant/après, tests de qualité automatisés (pytest)
- **Yacine (PO)** : arbitre les règles de traitement (supprimer, corriger, imputer, signaler)

Sprint 3 : Transformation et rapport de diagnostic (2-8 nov.)

Objectif : produire les variables d'analyse et remettre le livrable 3. *(Préparation)*

- **Jean Robert** : marge brute en valeur, ventes nettes des retours, marge après retours (hypothèse documentée)
- **Barnabé** : taux de retour, taux de remise effectif, tranches de remise, indicateur promotion et attributs de DimPromotion
- **Lamoussa** : agrégats par boutique, produit, promotion et période, séries hebdomadaires pour la prévision, indicateurs standardisés (par transaction, par jour de promotion, par m²)
- **Mouncif** : visuels de qualité des données, mise à jour du dictionnaire avec les variables dérivées
- **Toute l'équipe** : rédaction du rapport L3 (sources et modèle de données, diagnostic, règles de nettoyage, transformations, limites et hypothèses), relecture croisée coordonnée par Yacine

Sprint 4 : Analyse Q1 à Q4, modèle prédictif des retours et tableau de bord Excel (9-22 nov.)

Objectif : répondre aux quatre premières questions de recherche et expliquer le risque de retour. *(Analyse exploratoire, diagnostique et prédictive)*

- **Jean Robert** : Q1 côté boutiques (CA et marge en valeur par boutique, type et pays, productivité par m² et par employé) ; modèle prédictif du risque de retour (régression logistique, gradient boosting, AUC, facteurs expliqués avec SHAP)
- **Barnabé** : Q1 côté produits et temps (catégorie, sous-catégorie, marque, Pareto 80/20, saisonnalité et effet COVID-19, ANOVA des facteurs) ; tableau de bord Excel (Power Query, tableaux croisés dynamiques, segments et chronologie)
- **Lamoussa** : Q2 : volume, panier et marge en valeur, promo vs hors promo, par type de promotion, effet avant/pendant/après (uplift), tests statistiques
- **Mouncif** : Q3 (taux de retour standardisés par produit, catégorie, boutique et période, cas anormaux, relation prix et retours) et Q4 (corrélation remise et retour, contrôle des facteurs de confusion par régression)
- **Yacine (PO)** : valide les synthèses Q1 à Q4 et teste le tableau de bord Excel

Sprint 5 : Prédiction, simulation et optimisation des promotions (23 nov.-6 déc.)

Objectif : passer de « que s'est-il passé » à « que faut-il faire » sur les promotions, et présenter les conclusions et recommandations (L4). *(Analyse prédictive et prescriptive)*

- **Barnabé** : Q5 descriptive (marge en valeur par tranche de remise, élasticité du volume, seuils où la marge baisse ou les retours augmentent) ; modèle de réponse aux promotions (volume et marge attendus selon la remise, la catégorie, la boutique et la période, uplift incrémental par type de promotion)
- **Lamoussa** : modèle de prévision des ventes hebdomadaires (référence naïve, SARIMA, gradient boosting avec variables calendrier et promotion), évaluation MAE / MAPE ; reproduction de l'optimisation avec le Solveur Excel et le Gestionnaire de scénarios

- **Jean Robert** : simulation what-if de 6 scénarios ou plus (taux de remise de 0 à 30 %, catégories ciblées, périodes) à partir des modèles de retour et de réponse ; optimisation en Python : maximiser la marge nette des retours sous contraintes (budget de remise, volume minimal, taux de retour maximal) et comparer à la politique actuelle
- **Mouncif** : tableau de bord Power BI alimenté par data/clean et data/outputs (relations, mesures DAX, pages vue d'ensemble, boutiques avec carte, produits, promotions, retours) et page what-if avec paramètre de taux de remise, validation des mesures contre Python
- **Yacine (PO)** : assemble le rapport d'analyse (chaque membre rédige sa section) et sélectionne les visualisations clés
- **Achraf (SM)** : coordonne la présentation PowerPoint des conclusions et la démonstration des tableaux de bord, organise la répétition chronométrée

Sprint 6 : Plan promotionnel recommandé et rapport final (7-13 déc.)

Objectif : fiabiliser les recommandations, les transformer en plan d'action chiffré et remettre le rapport final (L5). *(Analyse prescriptive)*

- **Yacine (PO)** : formule et priorise les recommandations opérationnelles (impact, faisabilité)
- **Jean Robert** : analyse de sensibilité de la politique optimale (élasticité ±20 %, part de retours invendables de 0 à 100 %, budget de remise) ; intègre la rétroaction reçue lors de la présentation
- **Barnabé** : calendrier promotionnel recommandé (catégories, périodes, taux de remise) ; limites et pistes d'amélioration (données à collecter : motifs de retour, stocks, charges, clients)
- **Lamoussa** : prévision des ventes du trimestre suivant avec le plan recommandé vs le plan actuel ; compile les annexes (dictionnaire, code, captures des tableaux de bord)
- **Mouncif** : chiffrage des gains attendus et des risques du plan ; exécution complète de `run_pipeline.py` et archivage des notebooks exécutés ; relecture finale et mise en page
- **Achraf (SM)** : revue finale et rétrospective du projet

Correspondance avec les types d'analyses

Sprint	Type d'analyse
0	Cadrage et collecte
1-3	Préparation et descriptive
4	Exploratoire, diagnostique (Q1 à Q4) et prédictive (risque de retour)
5	Prédictive (ventes, réponse aux promotions) et prescriptive (simulation, optimisation)
6	Prescriptive (sensibilité, plan promotionnel)

Couverture des questions de recherche

Question	Descriptive / diagnostique	Prédictive	Prescriptive
Q1 : facteurs de performance	CA et marge par boutique, produit, période, Pareto, ANOVA (US17)	Importance des variables du modèle de prévision (US23)	Boutiques et catégories à prioriser (US26)
Q2 : effet des promotions	Promo vs hors promo, uplift observé (US18)	Modèle de réponse aux promotions (US29)	Scénarios what-if (US30)
Q3 : patterns de retour	Taux de retour standardisés, cas anormaux (US19)	Modèle du risque de retour (US28)	Seuils de remise et produits à surveiller (US31, US32)
Q4 : remises et retours	Corrélation contrôlée (US21)	Effet de la remise dans le modèle de retour (US28)	Contrainte de taux de retour maximal dans l'optimisation (US31)
Q5 : stratégie de prix	Marge par tranche de remise, élasticité (US22)	Volume et marge attendus par remise (US29)	Remise optimale par catégorie et plan promotionnel (US31, US32)

Hypothèses et limites

- Les données fournies correspondent à FactSales de Contoso Retail DW (vérifié sur échantillon, IdVente = SalesKey). L'utilisation des tables de dimension Contoso reste soumise à la validation du professeur ; à défaut, les tâches liées à la géographie, aux catégories et aux types de promotion seront remplacées par des dimensions dérivées des transactions.
- Les dates de Contoso sont décalées de 12 ans par rapport à nos données : toutes les dates des dimensions sont réalignées (+12 ans).
- La rentabilité est analysée en **marge brute en valeur** : les charges d'exploitation ne sont pas disponibles, la rentabilité nette et le seuil de rentabilité sont hors périmètre.
- La démarque (retours invendables, vol) n'est pas mesurable avec les données disponibles. La part de retours invendables est traitée comme un **paramètre** dans la simulation et l'optimisation, et son effet est testé dans l'analyse de sensibilité.
- Les modèles prédictifs et prescriptifs reposent sur des relations observées en 2020-2021 : l'élasticité estimée est descriptive et non causale, ce qui justifie l'analyse de sensibilité avant toute recommandation.
- Les fichiers fournis ne contiennent que 6 trimestres : octobre à décembre 2020 et 2021 sont absents. La saisonnalité des Fêtes ne peut pas être observée, et la prévision portera sur les trimestres 1 à 3. Point signalé au professeur.
- Les données couvrent un échantillon de 56 boutiques : les conclusions portent sur ce périmètre et non sur l'ensemble de l'entreprise.
- 2020 et 2021 sont marquées par la COVID-19 : les tendances temporelles seront interprétées en tenant compte des périodes de confinement.

- La présentation UA1 est supposée coïncider avec la remise du 5 octobre.