PROJET 4 · UNITÉ D'APPRENTISSAGE 2

# Analyse des données de vente et de retours

Diagnostic, nettoyage et transformation des données
Analyse exploratoire et conclusions

**Livrables 3 et 4**


ÉQUIPE

Yacine Lezoul, Product Owner
Achraf Chihab, Scrum Master
Jean Robert Joseph · Barnabe Landry Evouna · Lamoussa Sanogo · Mouncif Bouchachi



Science des données appliquées · Collège La Cité
Version du 7 octobre 2026

# Table des matières

**1. Objet du document** ..... **4**

**2. Les données : collectes supplémentaires et modèle** ..... **4**

2.1 Les sources ..... 4
2.2 Collecte 1 : les ventes complètes ..... 4
2.3 Collecte 2 : les charges, une deuxième table de faits ..... 5
2.4 Collecte 3 : le contexte, et la vérification du décalage de douze ans ..... 6
2.5 Le modèle de données ..... 6
2.6 Le périmètre retenu ..... 7

**3. État des lieux des données brutes** ..... **7**

**4. Diagnostic détaillé de la table des ventes** ..... **10**

4.1 Le registre en un coup d'œil ..... 10
4.2 Structure et types ..... 10
4.3 Valeurs manquantes ..... 10
4.4 Doublons ..... 11
4.5 Variables texte ..... 11
4.6 Plages de valeurs ..... 11
4.7 Règles de cohérence entre colonnes ..... 12
4.8 Cohérence des promotions ..... 12
4.9 Cohérence dans le temps ..... 13
4.10 Valeurs extrêmes ..... 13

**5. Règles de nettoyage et justification de chaque choix** ..... **14**

5.1 Règle N1 : espaces en trop ..... 14
5.2 Règle N2 : colonnes sans information ..... 14
5.3 Règle N3 : promotions hors période ..... 15
5.4 Règle N4 : grandes quantités ..... 15
5.5 Règle N5 : types techniques ..... 15
5.6 Règle N6 : remise sur plus d'unités que la vente ..... 15
5.7 Règle N7 : effectif manquant d'un magasin ..... 16
5.8 Le coût total : recalculé, pas corrigé ..... 17
5.9 Ce que nous avons choisi de ne pas faire ..... 17

**6. Validation et transformations** ..... **18**

6.1 La validation du nettoyage ..... 18
6.2 Les variables dérivées ..... 18
6.3 Les tables agrégées ..... 19

**7. Ce que le diagnostic dit de la nature des données** ..... **19**

7.1 Un jeu de données généré, pas une activité réelle ..... 19
7.2 Les charges sont, elles aussi, générées par des règles ..... 20
7.3 L'effectif et la masse salariale ne sont pas cohérents entre eux ..... 21
7.4 Ce que le projet peut conclure, et ce qu'il ne peut pas ..... 21

**8. Méthode de l'analyse** ..... **22**

8.1 Les questions ..... 22
8.2 Les règles de lecture ..... 22
8.3 Les méthodes employées ..... 22

**9. Q1 : les facteurs déterminants de la performance des ventes** ..... **23**

9.1 Vue d'ensemble ... 23
9.2 Le temps ... 24
9.3 Les produits ... 24
9.4 Les boutiques ... 24
9.5 Le poids de chaque facteur ... 24
9.6 Pourquoi les ventes baissent : le catalogue vieillit ... 26
9.7 L'usure du catalogue résiste-t-elle aux tests ? ... 28

**10. Q1, suite : la rentabilité après charges et les leviers ... 29**
10.1 Ce que deviennent 100 $ de ventes ... 29
10.2 Le déficit des magasins est saisonnier ... 30
10.3 Le détail des charges ... 30
10.4 Charges fixes et charges variables ... 31
10.5 Les charges ont augmenté pendant que les ventes baissaient ... 31
10.6 Une piste : regrouper l'administration et l'informatique par pays ... 32
10.7 La publicité : une grille plutôt qu'une prévision ... 32
10.8 Les leviers de rentabilité, par an ... 33

**11. Q2 : l'effet des promotions ... 34**
11.1 Comment les promotions sont distribuées ... 34
11.2 Le piège : promotion et saison sont confondues ... 34
11.3 Trois angles pour contourner le problème ... 35
11.4 Ce que coûtent les promotions ... 36

**12. Q5 : les niveaux de remise et la marge ... 36**
12.1 Pourquoi nous ne cherchons pas un « taux optimal » ... 36
12.2 À saison égale, plus de remise ne fait pas vendre plus ... 36
12.3 De quoi est faite une ligne remisée ... 37
12.4 Deux réalités opposées selon le type de boutique ... 37
12.5 Une remise plus forte ne rapporte nulle part davantage ... 38
12.6 Chaque décision, bornée par deux lectures ... 39

**13. Q3 et Q4 : les retours ... 40**
13.1 À quoi ressemble un retour ... 40
13.2 Choisir la bonne mesure avant de comparer ... 40
13.3 Aucun facteur ne concentre les retours ... 40
13.4 Ce qui varie, c'est le coût ... 41
13.5 Q4 : les remises font-elles retourner davantage ? ... 42
13.6 Les retours ne se prédisent pas ... 42

**14. Synthèse des réponses ... 42**

**15. Conclusion : mise à jour du backlog, des notebooks et suite du projet ... 44**
15.1 Bilan ... 44
15.2 Mise à jour du backlog ... 44
15.3 Mise à jour des notebooks ... 45
15.4 La suite : ce qui est prévu pour la prochaine unité ... 45

**Annexe : fichiers produits et notebooks ... 47**
Fichiers produits par le nettoyage et les transformations ... 47
Notebooks de préparation ... 47
Notebooks d'analyse et classeurs de résultats ... 47

PREMIÈRE PARTIE · LIVRABLE 3

# Les données, du brut au propre

## 1. Objet du document

Ce document réunit deux livrables du projet 4. La première partie présente le diagnostic de qualité, le nettoyage et la transformation des données : dans quel état étaient les données, qu'avons-nous corrigé et pourquoi. La seconde partie présente l'analyse, dans l'ordre de la présentation orale (Q1, puis Q2 et Q5 qui traitent toutes deux des promotions, puis Q3 et Q4 sur les retours) : les réponses aux cinq questions de recherche et les recommandations qui en découlent. Les deux sont réunis parce que la seconde s'appuie à chaque pas sur les limites établies par la première.

Chaque chiffre de ce document est produit par un notebook du dépôt, cité entre parenthèses. Rien n'a été corrigé à la main.

## 2. Les données : collectes supplémentaires et modèle

Depuis le cadrage, l'équipe a mené trois collectes supplémentaires. Elles changent l'ampleur du projet : les ventes passent de 144 874 à 376 234 lignes, une deuxième table de faits apporte les charges de chaque boutique, et des données de contexte sont rattachées à chaque vente.

### 2.1 Les sources

| Source | Contenu | Usage dans le projet |
|---|---|---|
| Ventes (base Contoso Retail DW de Microsoft, table `FactSales`) | Une ligne par jour, boutique, produit et promotion, 2020 et 2021 | Table de faits principale |
| Tables de dimension Contoso | Boutiques, géographie, produits, sous-catégories, catégories, promotions, canaux | Attributs joints aux ventes (modèle en flocon) |
| Plan stratégique Contoso (`FactStrategyPlan`) | Ventes, coût des ventes et charges par boutique et par mois, en réel, budget et prévision | Deuxième table de faits : rentabilité après charges |
| Données de contexte collectées par l'équipe | Jours fériés et sévérité du COVID-19, par pays et par jour | Variables de contexte |

L'encodage des fichiers (UTF-8 avec marque d'ordre, lu en `utf-8-sig`) a été vérifié table par table et justifié dans le livrable précédent. Il n'est pas repris ici.

## 2.2 Collecte 1 : les ventes complètes

Première collecte supplémentaire. Les six fichiers fournis au départ ne contiennent qu'une partie des ventes de nos 56 boutiques : cinq catégories de produits sur huit, et les trimestres 1 à 3 de chaque année. À l'intérieur de ce périmètre rien ne manque, puisque chacune des 144 874 lignes fournies se retrouve à l'identique dans la base. Ce n'est donc pas un échantillon, c'est un sous-périmètre.

Avec l'accord du professeur, le projet travaille depuis le 6 octobre sur les **ventes complètes** des mêmes boutiques, extraites de la base dans le même format.

| | Fichiers fournis | Ventes complètes | Écart |
|---|---|---|---|
| Lignes | 144 874 | 376 234 | × 2,6 |
| Chiffre d'affaires | 542,5 M$ | 1 466,6 M$ | les fichiers fournis en couvrent 37 % |
| Catégories de produits | 5 | 8 | Home Appliances, Cameras and camcorders et Games and Toys ajoutées |
| Trimestres | 6 | 8 | les deux quatrièmes trimestres ajoutés |

Trois raisons justifient ce choix :

- **Les charges.** Le plan stratégique donne les charges de chaque boutique. Ses ventes et son coût des ventes sont égaux aux totaux des ventes complètes **au cent près** (769 217 766,00 $ en 2020 et 697 375 893,85 $ en 2021). Ils ne sont pas comparables au périmètre partiel. La rentabilité d'une boutique n'est calculable qu'avec les ventes complètes.
- **Le poids de ce qui manquait.** Les trois catégories absentes représentent 52 % du chiffre d'affaires. La première catégorie de l'entreprise, Home Appliances (33 %), n'était pas dans les fichiers.
- **La saisonnalité.** Sans les quatrièmes trimestres, la fin d'année et la promotion des Fêtes, la plus forte, étaient tronquées.

Le périmètre d'origine reste reproductible : une seule variable de configuration (`SOURCE_VENTES`) permet d'y revenir.

## 2.3 Collecte 2 : les charges, une deuxième table de faits

Deuxième collecte supplémentaire. Les fichiers fournis ne contenaient aucune charge : ils permettaient de calculer une marge, pas de savoir si une boutique gagne de l'argent. L'exploration de la base Contoso a fait apparaître le **plan stratégique** (`FactStrategyPlan`), qui donne pour chaque boutique et chaque mois les ventes, le coût des ventes, six comptes de frais généraux, huit comptes de publicité et les impôts, en réel, en budget et en prévision.

| Élément | Valeur |
|---|---|
| Lignes extraites | 355 236, pour nos 56 boutiques et les 24 mois |
| Une ligne représente | une boutique, un mois, un scénario, un compte, une catégorie de produit |

| Élément | Valeur |
|---|---|
| Comptes | 17 comptes de détail, traduits en français et regroupés en familles |
| Scénarios | Réel, budget, prévision |
| Tables de dimension associées | `DimAccount` (comptes), `DimScenario` (scénarios), `DimEntity` (lien entre une boutique et son entité dans le plan) |

**La preuve que cette table décrit bien nos boutiques** : ses ventes et son coût des ventes sont égaux aux totaux de nos ventes complètes au cent près, boutique par boutique et mois par mois.

Cette table suit la même démarche que les ventes : chargement, mise en forme, diagnostic, variables, validation. Son diagnostic ne trouve aucune anomalie : aucun vide, aucun doublon sur la clé, aucun montant négatif ou nul, une seule devise, et les mois couverts par le plan sont exactement les mois de vente de chaque boutique, y compris pour les trois magasins ouverts en cours de période.

Les 17 comptes sont traduits en français et regroupés en familles : ventes, coût des ventes, frais généraux (personnel, loyers, administration, informatique, énergie, autres charges), publicité (huit comptes par campagne et par média) et impôts. Le résultat d'exploitation de chaque boutique s'en déduit : marge nette des retours, moins frais généraux, moins publicité.

## 2.4 Collecte 3 : le contexte, et la vérification du décalage de douze ans

Troisième collecte supplémentaire. L'équipe a réuni les jours fériés de 2020 et 2021 pour les 17 pays des boutiques (396 lignes) et un indice quotidien de sévérité du COVID-19 par pays (12 427 lignes). Ces deux tables sont réunies en une seule table de contexte, par pays et par jour, rattachée à chaque vente.

Les ventes fournies sont celles de Contoso, datées de 2008 et 2009, décalées de douze ans. Nous l'avons vérifié : une fois les dates des promotions décalées de douze ans, 99,55 % des ventes en promotion tombent dans la période de leur promotion. Avec un décalage de onze ou de treize ans, ce taux tombe à moins de 1 % (`00_inventaire`, section 7). Toutes les dates des dimensions (promotions, ouverture des boutiques, mise en vente des produits) ont donc été réalignées de douze ans.

## 2.5 Le modèle de données

Les ventes sont organisées en **modèle en flocon** (`02_flocon`) : la table des ventes est reliée aux boutiques, aux produits, aux promotions, aux canaux et au calendrier, et certaines dimensions sont elles-mêmes reliées à d'autres (la boutique à sa géographie, le produit à sa sous-catégorie puis à sa catégorie).

L'intégration des charges ajoute une **deuxième table de faits** (`05b_charges`). Les charges ne pouvaient pas devenir des colonnes de la table des ventes, parce qu'elles ne sont pas au même niveau de détail : un loyer mensuel n'appartient à aucune vente en particulier.

| | Ventes | Charges |
|---|---|---|
| Une ligne représente | un produit, une boutique, un jour, une promotion | une boutique, un mois, un compte, un scénario, une catégorie |

| | Ventes | Charges |
|---|---|---|
| Lignes | 376 234 | 355 236 |
| Dimensions partagées | boutique, date, catégorie de produit | boutique, mois, catégorie de produit |
| Dimensions propres | produit, promotion, canal | compte, scénario |

### 2.6 Le périmètre retenu

| Élément | Valeur |
|---|---|
| Lignes de vente | 376 234 |
| Période | du 1er janvier 2020 au 31 décembre 2021, 731 jours, aucun jour sans vente |
| Chiffre d'affaires brut | 1 466 593 660 $ |
| Boutiques | 56 : 54 magasins, une boutique en ligne, un revendeur |
| Pays | 17, tous en Europe |
| Produits | 2 508, dans 8 catégories, 32 sous-catégories et 11 marques |
| Promotions | 14, dont l'absence de promotion |

## 3. État des lieux des données brutes

Avant de parler de nettoyage, il faut dire dans quel état les données sont arrivées. Le tableau suivant décrit chaque table telle qu'elle a été reçue, avant toute transformation. La taille est donnée en lignes × colonnes (`00_inventaire` pour les ventes et les dimensions, `05b_charges` pour le plan stratégique). Une valeur manquante est une cellule vide. Un doublon est soit une ligne entièrement répétée, soit une clé primaire répétée.

| Table | Taille | Valeurs manquantes | Doublons | Types à corriger | Commentaire |
|---|---|---|---|---|---|
| **Ventes** (8 fichiers) | 376 234 × 14 | Aucune | Aucun | Tout est lu comme du texte : date vers date, identifiants et quantités vers entiers, montants vers décimaux. Dans les fichiers fournis, les montants étaient écrits « $1,062.60 » | Une ligne est un cumul journalier, pas un ticket de caisse. Voir la section 4 |

| Table | Taille | Valeurs manquantes | Doublons | Types à corriger | Commentaire |
|---|---|---|---|---|---|
| **Boutiques** | 306 × 25 | 685 cellules sur 7 colonnes : date et motif de fermeture (294), code postal (41), adresse (7), **effectif (1)** | Aucun | Dates en texte, effectif et surface en décimaux | Source : `DimStore`. 56 boutiques utilisées par nos ventes (18 %). L'effectif manquant est celui d'un de nos magasins : règle N7 |
| **Géographie** | 674 × 10 | 307 cellules sur 4 colonnes, surtout la ville (157) | Aucun | Aucun | Source : `DimGeography`. Vides normaux : une ligne de niveau pays ou région n'a pas de ville. Aucune boutique sans géographie |
| **Produits** | 2 517 × 32 | 13 988 cellules sur 12 colonnes, dont 5 colonnes entièrement vides (taille, adresses web, date de fin de vente) | Aucun | Dates en texte, prix et coût en décimaux | Source : `DimProduct`. 2 508 produits vendus. Les colonnes vides ne sont pas reprises. Espaces en trop dans certains libellés : règle N1 |
| **Sous-catégories** | 44 × 8 | Aucune | Aucun | Aucun | Source : `DimProductSubcategory`. 32 sous-catégories utilisées. Aucun produit sans sous-catégorie |
| **Catégories** | 8 × 7 | Aucune | Aucun | Aucun | Source : `DimProductCategory`. Les 8 catégories sont utilisées |
| **Promotions** | 28 × 14 | 56 cellules : quantités minimale et maximale, entièrement vides | Aucun | Dates en texte, taux en décimal | Source : `DimPromotion`. 14 promotions utilisées. Aucune règle de remise n'est décrite : voir la section 4.8. Libellé d'origine avec une coquille (« Back-to-Scholl »), conservé |
| **Calendrier Contoso** | 2 556 × 29 | 5 328 cellules sur 4 colonnes : nom du jour férié entièrement vide, saisons | Aucun | Sans objet | Source : `DimDate`. Non reprise : elle couvre 2005 à 2011 et ne contient aucun jour férié. Le calendrier 2020 et 2021 est reconstruit |
| **Canaux** | 4 × 7 | Aucune | Aucun | Aucun | Source : `DimChannel`. 3 canaux utilisés, un par type de boutique |
| **Devises** | 28 × 7 | Aucune | Aucun | Aucun | Source : `DimCurrency`. Écartée : toutes nos ventes sont dans une seule devise |

| Table | Taille | Valeurs manquantes | Doublons | Types à corriger | Commentaire |
|---|---|---|---|---|---|
| **Charges** | 355 236 × 9 | Aucune | Aucun | Date en texte | Source : `FactStrategyPlan`. 56 boutiques, 24 mois, 3 scénarios, 17 comptes. Aucun montant négatif ou nul. Ventes égales aux nôtres au cent près |
| **Comptes** | 24 × 13 | 31 cellules sur 6 colonnes techniques | Aucun | Aucun | Source : `DimAccount`. Hiérarchie de comptes. Les 17 comptes de détail sont repris et traduits |
| **Scénarios** | 3 × 7 | Aucune | Aucun | Aucun | Source : `DimScenario`. Réel, budget, prévision |
| **Entités** | 421 × 13 | 427 cellules, dont la date de fin entièrement vide | Aucun | Aucun | Source : `DimEntity`. Fait le lien entre une boutique et son entité dans le plan |
| **Jours fériés** (collecte) | 396 × 4 | Aucune | Aucun | Date en texte | 17 pays, 2020 et 2021 |
| **Sévérité COVID-19** (collecte) | 12 427 × 3 | Aucune | Aucun | Date en texte, indice en décimal | Un indice par pays et par jour |
| **Clients** | 18 869 × 29 | Nombreuses | Sans objet | Sans objet | Source : `DimCustomer`. Non retenue : `FactSales` ne contient aucune clé client |
| **Employés** | 293 × 27 | Peu | Sans objet | Sans objet | Source : `DimEmployee`. Non retenue : liste d'employés sans clé vers une boutique. Elle ne permet pas de connaître le personnel d'un magasin |

### Ce qu'il faut retenir de ce tableau

- **Aucun doublon** dans aucune table : ni ligne répétée, ni clé primaire répétée. Les clés des ventes existent toutes dans les dimensions (100 % de correspondance pour les boutiques, les produits et les promotions), et aucune dimension n'a d'orphelin.
- **Les valeurs manquantes sont presque toutes normales** : une boutique ouverte n'a pas de date de fermeture, un pays n'a pas de ville. Une seule concerne nos analyses : l'effectif d'un magasin.
- **Les types** : les fichiers arrivent en texte. La conversion est faite une fois, dans `01_etl`, par un module commun (`src/etl.py`), et aucune valeur n'a échoué à la conversion.
- **Deux tables ne sont pas retenues parce qu'elles ne se rattachent à rien** : les clients et les employés. Cette absence a des conséquences sur ce que le projet peut conclure (section 7).

# 4. Diagnostic détaillé de la table des ventes

Le diagnostic porte sur la table des ventes jointes à ses dimensions : 376 234 lignes et 45 colonnes (`03_diagnostic`). Il observe et compte, sans rien modifier. Chaque contrôle est inscrit dans un registre, avec le nombre de lignes concernées, une gravité et une action proposée.

## 4.1 Le registre en un coup d'œil

| Gravité | Contrôles | Signification |
|---|---|---|
| OK | 34 | Le contrôle ne trouve aucune anomalie |
| Information | 11 | Particularité à connaître, sans correction |
| À corriger | 5 | Correction évidente, sans choix à faire |
| À décider | 6 | Plusieurs traitements possibles : l'équipe choisit et justifie |
| **Total** | **56** | |

## 4.2 Structure et types

Après conversion, les 45 colonnes ont le type attendu : aucune colonne de dates n'est restée en texte, aucune colonne numérique non plus, et aucune date de vente ne porte une heure autre que minuit.

## 4.3 Valeurs manquantes

Trois colonnes sur 45 contiennent des vides.

| Colonne | Lignes vides | Part | Nature du manque |
|---|---|---|---|
| `date_fermeture` | 376 234 | 100 % | **Normal** : aucune de nos boutiques n'a fermé |
| `nom_ferie` | 365 720 | 97,2 % | **Normal** : un jour ordinaire n'a pas de nom de jour férié. La colonne `est_ferie` est complète |
| `effectif` | 3 209 | 0,85 % | **Manque dans la source** : un seul magasin, Contoso Cheshire Store |

Nous distinguons trois sortes de manque : le manque normal (l'information n'existe pas), le manque dans la source (Contoso ne l'a pas renseignée), et le manque créé par nous (une jointure qui ne trouve pas de correspondance). Seul le troisième signalerait une erreur de notre chaîne, et il n'y en a aucun : aucune vente n'a de vide dans une mesure, une clé ou un attribut joint.

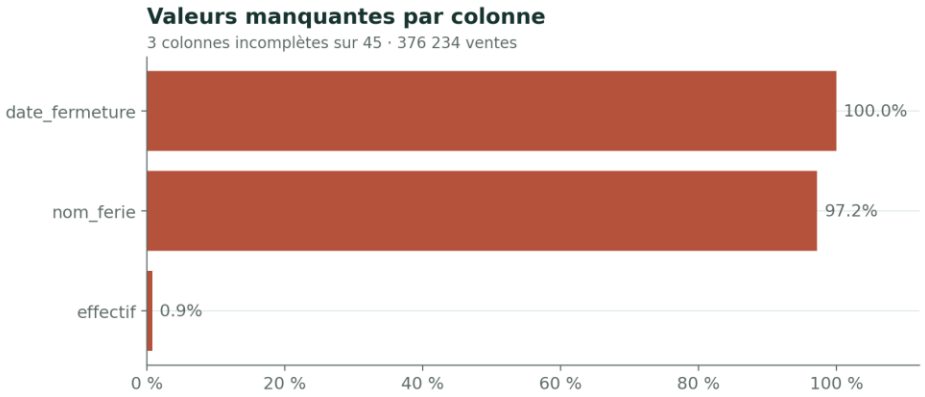



*Figure 1. Les trois colonnes qui contiennent des valeurs manquantes*

## 4.4 Doublons

Trois niveaux ont été contrôlés, du plus strict au plus large : ligne entièrement identique, identifiant de vente répété, clé métier répétée (même jour, même boutique, même produit, même promotion, même canal). Les trois contrôles donnent zéro.

Le troisième a une conséquence importante : il n'existe **jamais deux lignes** pour un même produit, dans une même boutique, le même jour. Une ligne n'est donc pas un achat, c'est le cumul de la journée (section 7.1).

## 4.5 Variables texte

| Colonne | Lignes touchées | Problème |
|---|---|---|
| `categorie` | 55 775 | Espace en fin de libellé : « Cameras and camcorders » écrit de deux façons |
| `marque` | 27 897 | Espaces en trop : 15 écritures pour 11 marques réelles |
| `sous_categorie` | 22 784 | Espace en fin de libellé sur deux sous-catégories |
| `nom_boutique` | 10 482 | Double espace dans le nom de deux magasins de Moscou |
| `nom_produit` | 504 | Double espace dans trois noms de produits |

Sans correction, la marque « Litware » et la marque « Litware » suivie d'un espace forment deux groupes distincts dans tous les classements. C'est l'anomalie la plus étendue du jeu de données (15 % des lignes pour la catégorie), et la plus simple à corriger.

Deux colonnes n'apportent aucune information : `continent` ne prend qu'une valeur (Europe) et `date_fermeture` est entièrement vide.

## 4.6 Plages de valeurs

Aucune quantité, aucun prix, aucun coût et aucun montant n'est négatif ou nul. Aucun taux de remise annoncé ne sort de l'intervalle de 0 à 100 %. 45,4 % des lignes n'ont aucune remise et 85,4 % n'ont aucun retour.

## 4.7 Règles de cohérence entre colonnes

Les colonnes d'une vente sont liées par des formules. Nous avons recalculé chaque colonne à partir des autres et comparé au cent près.

| Règle | Formule vérifiée | Lignes en écart | Verdict |
|---|---|---|---|
| R1 | Montant des ventes = prix unitaire × quantité vendue − remise | 0 | Respectée |
| R2 | Remise = prix unitaire × quantité remisée × taux annoncé | 0 | Respectée |
| R3 | Montant du retour = prix unitaire × quantité retournée | 0 | Respectée |
| R4 | Coût total = coût unitaire × quantité vendue | 43 730 (11,6 %) | **Non respectée** : voir ci-dessous |
| R5 | Quantité retournée ≤ quantité vendue | 0 | Respectée |
| R5 | Quantité remisée ≤ quantité vendue | 386 (0,10 %) | **Non respectée** : règle N6 |
| R6 | Prix et coût de la vente = prix et coût du catalogue | 0 | Respectée : les prix ne varient jamais |
| R7 | Prix unitaire ≥ coût unitaire | 0 | Respectée : aucune vente à perte avant remise |

**Ce que la règle R1 nous apprend.** Le montant des ventes est un montant **brut** : les retours n'en sont pas déduits. Nous l'avons vérifié en testant l'hypothèse inverse, qui est fausse sur 54 926 lignes. Le chiffre d'affaires net des retours doit donc être calculé par nous.

**Le coût total est calculé de trois façons.** Sur les lignes sans retour, la règle R4 est toujours respectée. Sur les 54 926 lignes avec retour, la source applique trois logiques différentes :

| Logique du coût total sur une ligne avec retour | Lignes | Part |
|---|---|---|
| Coût des unités vendues, moins les unités retournées | 42 848 | 78 % |
| Coût de toutes les unités vendues, retour ignoré | 11 196 | 20 % |
| Coût réduit de plus d'unités que le retour déclaré | 882 | 2 % |

La logique change d'une année à l'autre et selon la taille de la ligne, sans règle apparente. L'écart cumulé est de 6,9 M$, soit 1,1 % du coût total. Comme le coût sert à calculer la marge, notre mesure centrale, nous ne pouvions pas le laisser tel quel (section 5, traitement du coût).

## 4.8 Cohérence des promotions

- **1 258 ventes (0,33 %) sont datées hors de la période de leur promotion.** Toutes portent la promotion des Fêtes de l'édition 2021 (octobre 2021 à janvier 2022) alors qu'elles datent de janvier 2021. Une promotion jumelle, de même nom et de même taux, était bien en cours à ces dates.

- **72 629 ventes (19,3 %) sont rattachées à une promotion sans qu'aucune unité ne soit remisée.** Être « en promotion » ne veut donc pas dire recevoir une remise.
- **Le taux annoncé n'est presque jamais atteint.** Sur 99,7 % des lignes en promotion, le taux de remise réel est inférieur au taux annoncé, parce que la remise ne porte que sur une partie des unités de la ligne.

| Taux annoncé | Lignes | Taux réel moyen | Taux réel maximal |
|---|---|---|---|
| 5 % | 861 | 1,00 % | 10 % |
| 7 % | 85 399 | 0,78 % | 14 % |
| 10 % | 65 174 | 2,02 % | 20 % |
| 20 % | 126 754 | 4,55 % | 40 % |

Nous sommes retournés à la table d'origine des promotions pour chercher la règle. Elle ne contient rien : la description recopie le nom, les quantités minimale et maximale sont vides pour les 28 promotions, et toutes ont le même type. Nous avons aussi testé trois règles possibles (remise sur tout l'achat, sur la deuxième unité, sur la troisième unité) : aucune n'explique plus de 9 % des lignes. **Le mécanisme des promotions est inconnu**, et nous le signalons comme une incohérence des données.

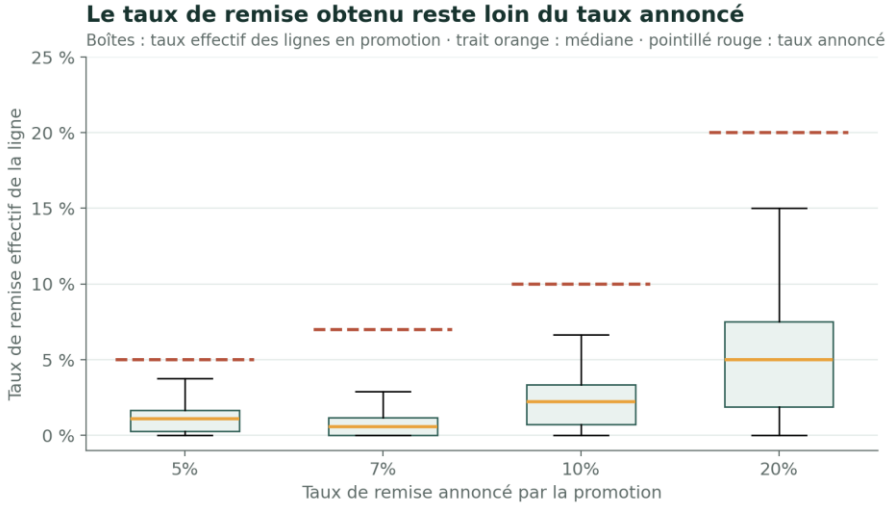



*Figure 2. Le taux de remise réellement obtenu, comparé au taux annoncé (trait rouge)*

## 4.9 Cohérence dans le temps

Les 731 jours de la période ont tous des ventes. Aucune vente n'est datée avant l'ouverture de sa boutique. Trois magasins ont ouvert en cours de période (Marseille en avril 2020, Berlin en octobre 2020, Venise en juillet 2021) : ils ne vendent pas sur les 24 mois, ce dont toutes les comparaisons entre magasins tiennent compte.

## 4.10 Valeurs extrêmes

Par la méthode de l'écart interquartile, 30 557 lignes (8,1 %) ont une quantité supérieure à la borne haute de 26,5 unités. Elles pèsent 38 % des unités vendues.

Extrême ne veut pas dire faux. Ces lignes respectent toutes la règle R1, et elles se trouvent là où on les attend : 15 % des lignes de la boutique en ligne et 9 % de celles du revendeur, contre 3 % en magasin. Les cinq plus grandes quantités (jusqu'à 2 880 unités) portent sur des accessoires à moins de 10 $.

# 5. Règles de nettoyage et justification de chaque choix

Le principe retenu par l'équipe est de **toucher le moins possible aux données** : aucune ligne n'est supprimée, aucun montant n'est modifié, et chaque modification laisse une trace. Sept règles sont appliquées (`04_nettoyage`), plus un traitement du coût dans le calcul des variables (`05_variables`).

| Règle | Ce qu'elle fait | Lignes touchées | Valeurs modifiées |
|---|---|---|---|
| N1 | Retire les espaces en trop dans les colonnes texte | jusqu'à 55 775 par colonne | Libellés seulement. Les marques passent de 15 à 11 |
| N2 | Supprime `continent` et `date_fermeture` | toutes | Aucune : colonnes sans information |
| N3 | Ajoute l'indicateur `promo_hors_periode` | 1 258 | Aucune |
| N4 | Ajoute l'indicateur `grande_quantite` | 30 557 | Aucune |
| N5 | Harmonise les types techniques | 0 | Aucune |
| N6 | Ramène la quantité remisée à la quantité vendue, ajoute `remise_corrigee` | 386 | Une quantité. Aucun montant |
| N7 | Impute l'effectif manquant d'un magasin, ajoute `effectif_impute` | 3 209 (un magasin) | Un effectif |

## 5.1 Règle N1 : espaces en trop

**Constat.** Une même modalité est écrite de deux façons dans cinq colonnes (section 4.5).

**Choix.** Retirer les espaces de début et de fin et réduire les doubles espaces. La même règle est appliquée aux tables de dimension, pour qu'un libellé s'écrive de la même façon partout, y compris dans Power BI.

**Pourquoi.** C'est une correction sans alternative : aucune information n'est perdue, et sans elle les regroupements par marque ou par catégorie sont faux.

## 5.2 Règle N2 : colonnes sans information

**Choix.** Supprimer `continent` (une seule valeur) et `date_fermeture` (entièrement vide).

**Pourquoi.** Une colonne constante ne peut rien expliquer. La garder alourdit la table et laisse croire à une information qui n'existe pas. La suppression est sans risque : les deux colonnes restent dans la dimension des boutiques d'origine.

## 5.3 Règle N3 : promotions hors période

### Options envisagées

| Option | Verdict | Raison |
|---|---|---|
| Supprimer les 1 258 ventes | Écartée | Les ventes et leurs remises sont réelles : les montants respectent toutes les règles |
| Remplacer l'identifiant par celui de la promotion jumelle | Écartée | Ce serait inventer une information. Rien ne prouve que la jumelle est la bonne |
| **Garder les ventes telles quelles et les signaler** | **Retenue** | Aucune donnée n'est modifiée, et l'indicateur permet de les exclure d'une analyse des promotions |

## 5.4 Règle N4 : grandes quantités

### Options envisagées

| Option | Verdict | Raison |
|---|---|---|
| Supprimer les lignes extrêmes | Écartée | Elles représentent 38 % des unités vendues et sont cohérentes |
| Les plafonner à la borne | Écartée | On fausserait le chiffre d'affaires, qui est égal au plan stratégique au cent près |
| **Les garder et les signaler** | **Retenue** | Les analyses choisissent : médiane plutôt que moyenne, ou exclusion par l'indicateur |

Cet indicateur a servi dès l'analyse des remises : la comparaison des lignes remisées et non remisées est faite sur les lignes courantes, parce que quelques très grosses lignes suffisent à déplacer une moyenne.

## 5.5 Règle N5 : types techniques

Certaines colonnes avaient un type dit « nullable », que plusieurs outils lisent mal. Elles sont converties vers le type standard équivalent. Aucune valeur ne change : le journal le vérifie colonne par colonne.

## 5.6 Règle N6 : remise sur plus d'unités que la vente

**Constat.** Sur 386 lignes, la quantité remisée dépasse la quantité vendue : par exemple 2 unités vendues et 4 remisées. Toutes datent de 2021, toutes sont dans la sous-catégorie Washers & Dryers, et les 56 boutiques sont touchées. Ces lignes n'existaient pas dans les fichiers fournis, puisqu'elles viennent de la catégorie Home Appliances.

**Comment nous avons tranché.** Sans équipe métier à interroger, nous avons testé trois explications en regardant sur combien d'unités portent le coût, le chiffre d'affaires et la remise.

| Hypothèse | Ce qu'on devrait observer | Ce qu'on observe |
|---|---|---|
| Unités offertes : 4 unités sorties, dont 2 gratuites | Le coût porte sur 4 unités | Le coût porte sur 2 unités : **écartée** |
| Pack « une achetée, une offerte » | La quantité remisée est un multiple de la quantité vendue, et le même schéma existe ailleurs | On trouve 3 pour 2, 4 pour 3, 7 pour 6. Dans les autres boutiques, la même promotion ne dépasse jamais la quantité vendue : **écartée** |
| Erreur sur la quantité remisée | La quantité remisée est sans lien avec la quantité vendue | La quantité remisée prend les valeurs 0 à 4 avec la même fréquence, quelle que soit la quantité vendue : **retenue** |

L'explication tient en une phrase : en 2020 ces produits se vendaient au minimum par 4, donc une quantité remisée de 0 à 4 ne dépassait jamais. En 2021 ils se vendent par 2 ou 3, et la même répartition dépasse. C'est un effet de la génération du fichier.

**Choix.** Appliquer une règle vraie dans tout commerce et respectée par toutes les autres lignes : on ne remise pas plus d'unités qu'on n'en vend. La quantité remisée est ramenée à la quantité vendue.

**Pourquoi ne pas recalculer la remise.** Le chiffre d'affaires et le coût de ces lignes sont cohérents avec la quantité vendue, et nos totaux sont égaux à ceux du plan stratégique au cent près. Recalculer la remise aurait augmenté le chiffre d'affaires de 174 036 $ et créé un écart avec les charges du plan. Les montants sont donc conservés.

**Limite assumée.** Sur ces lignes, la remise conservée dépasse ce que donnerait le taux annoncé : leur taux de remise réel monte jusqu'à 40 % pour une promotion à 20 %. L'indicateur `remise_corrigee` permet de les isoler, et les quantités d'origine sont conservées dans un fichier de corrections. L'enjeu est de 0,10 % des lignes et 0,09 % du chiffre d'affaires.

## 5.7 Règle N7 : effectif manquant d'un magasin

**Constat.** L'effectif d'un magasin, Contoso Cheshire Store (Royaume-Uni, 680 $m^2$), est vide dans la source. C'est la seule valeur manquante qui concerne nos analyses.

**Pourquoi la traiter maintenant.** Dans une première version du nettoyage, ce vide était toléré : l'effectif ne servait à aucune des cinq questions de recherche. La suite du projet change la donne. La typologie des magasins et toute analyse des moyens par magasin ont besoin d'une valeur pour chacun. Un magasin sans effectif serait écarté d'un calcul sans que personne ne le voie.

**L'idée la plus naturelle, et pourquoi elle ne tient pas.** Nous disposons des charges de personnel de chaque magasin. On pourrait en déduire l'effectif : masse salariale divisée par le coût moyen d'un employé. Nous l'avons testé sur les 53 magasins dont l'effectif est connu, en estimant chacun à partir des autres (`05b_charges`, section 7).

| Mesure | Par la masse salariale | Par la médiane |
|---|---|---|
| Erreur moyenne | 53 % | 46 % |
| Erreur médiane | 32 % | 40 % |
| Magasins estimés à moins de 25 % près | 36 % | 40 % |

La déduction par la masse salariale se trompe de plus de 25 % pour près de deux magasins sur trois, et ne fait pas mieux qu'une simple médiane. La raison est que **la masse salariale ne dit presque rien de l'effectif** : la corrélation de rang entre les deux est nulle (−0,08), et le coût de personnel par employé varie de 5 300 $ à 51 900 $ par an selon le magasin. Deux magasins l'illustrent : Lisbonne et Strasbourg ont la même masse salariale (518 000 $ et 519 000 $ par an), pour 95 employés dans l'un et 10 dans l'autre.

### Options envisagées

| Option | Verdict | Raison |
|---|---|---|
| Laisser vide | Écartée | Le magasin disparaît de toute analyse qui utilise l'effectif |
| Supprimer le magasin | Écartée | Ses ventes et ses charges sont complètes et justes |
| Déduire l'effectif de la masse salariale | Écartée | Repose sur un lien qui n'existe pas dans les données |
| **Médiane des magasins comparables** | **Retenue** | Valeur centrale, insensible aux magasins à très gros effectif, et la plus simple à justifier |

**Règle.** L'effectif manquant est remplacé par la médiane des magasins du même pays et de même surface. Douze magasins britanniques de 680 m² servent de référence, et la valeur imputée est de **29 employés**. Si moins de cinq magasins étaient comparables, la règle élargirait au pays.

**Le choix change peu le résultat.** La déduction par la masse salariale aurait donné 31 employés. Les deux méthodes s'accordent donc à deux employés près pour ce magasin.

**Limite assumée.** L'effectif n'est lié ni à la masse salariale, ni à la surface, ni aux ventes : aucune méthode ne peut retrouver la vraie valeur. La valeur imputée est plausible, pas exacte. L'indicateur `effectif_impute` permet d'exclure ce magasin d'un calcul. Nous l'avons déjà fait : le coût moyen d'un employé, utilisé dans l'analyse des charges, est calculé sans lui.

## 5.8 Le coût total : recalculé, pas corrigé

**Constat.** Le coût total de la source suit trois logiques différentes sur les lignes avec retour (section 4.7).

**Choix.** La colonne d'origine n'est pas modifiée. Trois coûts homogènes sont recalculés avec une formule unique : le coût brut (coût unitaire × quantité vendue), le coût du retour (coût unitaire × quantité retournée) et le coût net (la différence).

**Pourquoi.** Corriger la colonne aurait rompu l'égalité avec le plan stratégique. La recalculer à côté garde la source intacte et donne une marge calculée de la même façon sur toutes les lignes.

**Hypothèse à connaître.** En retirant le coût du retour, nous supposons qu'un article retourné est remis en stock et que son coût est récupéré. Les données ne disent rien de l'état des articles retournés. Si un retour est invendable, la marge réelle est plus basse que celle que nous calculons.

### 5.9 Ce que nous avons choisi de ne pas faire

| Décision | Raison |
|---|---|
| Ne modifier aucun montant | Le chiffre d'affaires et le coût sont égaux au plan stratégique au cent près : c'est notre preuve que les données sont complètes |
| Ne supprimer aucune ligne | Aucune ligne n'est fausse au point d'être inutilisable |
| Ne pas corriger le mécanisme des promotions | Il est inconnu. Les remises enregistrées sont gardées, et le taux de remise réel est calculé à partir d'elles |
| Ne pas corriger la coquille « Back-to-Scholl » | C'est le libellé d'origine de Contoso : le corriger romprait le lien avec la source |
| Ne pas imputer le nom du jour férié | Le vide est l'information : le jour n'est pas férié |

## 6. Validation et transformations

### 6.1 La validation du nettoyage

Avant d'écrire la table propre, le notebook prouve que le nettoyage a fait ce qui était prévu **et rien d'autre**. Si un seul contrôle échoue, rien n'est écrit. Les 28 contrôles réussissent.

| Famille de contrôles | Ce qui est prouvé |
|---|---|
| Lignes | Même nombre de lignes (376 234), mêmes identifiants, dans le même ordre, tous uniques |
| Mesures | Les neuf mesures sont comparées ligne par ligne avant et après. Huit sont identiques. Une seule a changé, la quantité remisée, et seulement sur les 386 lignes de la règle N6 |
| Règle N6 | Après correction, la quantité remisée ne dépasse plus la quantité vendue sur aucune ligne, la règle R1 est respectée partout, et le chiffre d'affaires total est identique à la source (1 466 593 659,85 $) |
| Règle N7 | L'effectif n'a plus de vide. Les lignes imputées sont exactement celles dont l'effectif était vide, et l'effectif est inchangé partout ailleurs |
| Règle N1 | Plus aucun espace en trop, 15 marques ramenées à 11 |
| Règles N2 à N4 | Les deux colonnes sans information sont absentes, les indicateurs sont présents, de type vrai ou faux, sans vide |
| Vides | Une seule colonne contient encore des vides : `nom_ferie`, par construction |
| Colonnes | La table propre contient exactement les colonnes attendues : 47 |

**Trois fichiers de traçabilité accompagnent la table propre** : le journal de nettoyage (23 entrées, une par règle et par colonne, avec le nombre de lignes touchées et la justification), le fichier des corrections de la règle N6 (les 386 lignes avec leur quantité d'origine) et le rapport de validation (les 28 contrôles et leur résultat).

Le même principe est appliqué au calcul des variables (cohérence des variables entre elles) et aux charges (égalité des totaux avec le fichier extrait et avec la table des ventes).

### 6.2 Les variables dérivées

| Variable | Formule | Remarque |
|---|---|---|
| Chiffre d'affaires brut | montant des ventes | Colonne d'origine, inchangée |
| Chiffre d'affaires net | montant des ventes − montant du retour | Les retours ne sont pas déduits dans la source |
| Coût brut | coût unitaire × quantité vendue | Remplace le coût total de la source |
| Coût du retour | coût unitaire × quantité retournée | |
| Coût net | coût brut − coût du retour | |
| Marge brute | chiffre d'affaires brut − coût brut | En dollars |
| Marge nette des retours | chiffre d'affaires net − coût net | Notre mesure centrale, en dollars |
| Montant avant remise | prix unitaire × quantité vendue | |
| Taux de remise effectif | remise ÷ montant avant remise | Le taux réellement obtenu |
| Taux de retour | quantité retournée ÷ quantité vendue | |

S'y ajoutent des indicateurs (ligne en promotion, ligne avec remise, ligne avec retour) et des variables de calendrier (mois, semaine, jour de la semaine). La table des ventes passe ainsi de 47 à 67 colonnes.

#### Deux choix méritent d'être expliqués

- **La marge est suivie en valeur, pas en taux.** Une remise peut faire baisser le taux de marge tout en augmentant les dollars gagnés, si elle fait vendre davantage. C'est la marge en dollars que l'entreprise encaisse.
- **Le taux de remise effectif remplace le taux annoncé** dans toutes les analyses, puisque le taux annoncé n'est presque jamais celui que le client obtient.

### 6.3 Les tables agrégées

Sept tables agrégées sont produites pour les tableaux de bord et les modèles : par semaine, par boutique, par produit, par promotion, par pays et par mois, puis le compte de résultat par boutique, mois et scénario, et enfin une **table commune ventes et charges** par boutique et par mois (1 314 lignes). Dans toutes ces tables, les taux sont recalculés à partir des sommes du groupe et jamais comme une moyenne de taux.

## 7. Ce que le diagnostic dit de la nature des données

Le diagnostic ne s'est pas arrêté à la propreté des tables. En cherchant à comprendre chaque anomalie, nous avons établi plusieurs faits sur la **nature** de ces données. Ils déterminent ce que le projet peut conclure et ce qu'il ne peut pas conclure.

## 7.1 Un jeu de données généré, pas une activité réelle

Les données sont très propres sur le plan comptable. Nous avons donc posé une autre question : ressemblent-elles aux ventes d'un vrai commerce ? Cinq propriétés qu'une activité réelle aurait forcément ont été testées (`03_diagnostic`, section 11).

| Test | Dans un vrai commerce | Dans nos données |
|---|---|---|
| Grain de la ligne | Une ligne est un ticket, rattaché à un client | Aucune colonne de client ou de ticket. Jamais deux lignes pour un même produit, une même boutique, un même jour : la ligne est un **cumul journalier** |
| Quantités | Beaucoup de ventes d'une seule unité, surtout pour les produits chers | **Aucune** ligne d'une unité, même à plus de 1 000 $. Le minimum est de 2, et de 6 dans sept catégories sur huit. Huit quantités couvrent 88,5 % des lignes |
| Prix | Les prix bougent : inflation, baisse rapide de l'électronique | Sur les 2 240 produits vendus les deux années, **aucun** prix et aucun coût n'a changé |
| Régularité | L'activité varie selon le jour de la semaine | Chaque jour pèse entre 14,1 % et 14,4 % des lignes : répartition uniforme |
| COVID-19 | Chute des ventes en magasin pendant les confinements | Corrélation de +0,02 entre la sévérité et les ventes des magasins : aucune réaction |

Le dernier point s'explique par le décalage de douze ans : ces ventes datent en réalité de 2008 et 2009 et n'ont jamais connu les confinements. La règle N6 ajoute un sixième indice, puisque la quantité remisée est tirée sans lien avec la quantité vendue.

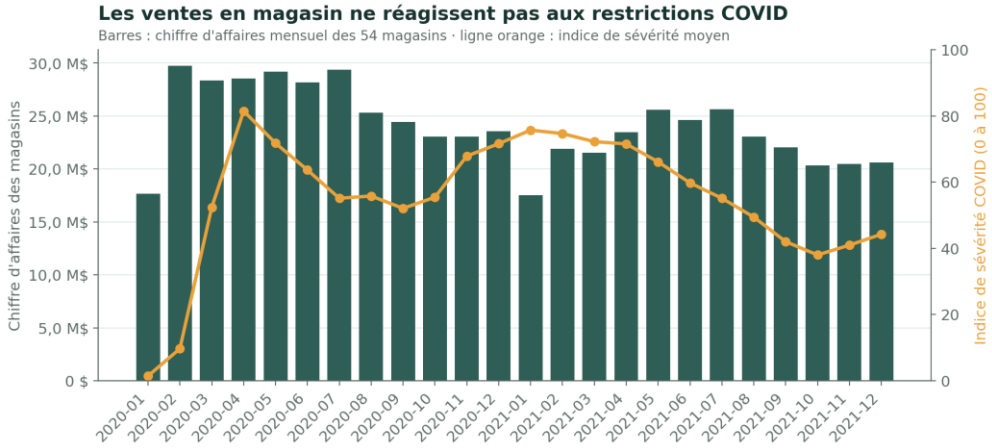



*Figure 3. Les ventes ne réagissent pas à la sévérité du COVID-19*

**Conclusion.** Le jeu de données est généré par des règles. Il est cohérent sur le plan comptable, mais il ne reflète pas un comportement d'achat.

## 7.2 Les charges sont, elles aussi, générées par des règles

L'examen du plan stratégique confirme ce constat du côté des charges (`05b_charges`, section 7).

- **La publicité est identique pour toutes les boutiques.** Chaque mois de campagne, les 18 mois sur 18, chaque boutique reçoit exactement le même montant au cent près, quelle que soit sa taille. La boutique en ligne, qui vend cinquante fois plus qu'un magasin, reçoit le même budget.
- **Les frais généraux suivent un taux appliqué aux ventes**, et les boutiques se rangent en deux groupes sans intermédiaire : dix boutiques entre 16 % et 25 % des ventes (la boutique en ligne, le revendeur et huit magasins), et 46 magasins entre 33 % et 37 %. L'écart se retrouve sur tous les comptes dans la même proportion.
- **Les charges ne suivent pas les moyens réels.** Les loyers ne sont pas liés à la surface (corrélation de +0,13), et le personnel ne suit pas l'effectif. La boutique en ligne déclare 7 employés pour 1,9 M$ de personnel par employé et par an.

L'explication qu'on donnerait dans la réalité (« une boutique en ligne n'a ni vitrine ni vendeurs ») n'est donc pas soutenue par ces données, et nous ne l'écrirons pas comme un résultat.

## 7.3 L'effectif et la masse salariale ne sont pas cohérents entre eux

C'est la découverte faite en traitant la valeur manquante (section 5.7), et elle dépasse le cas d'un seul magasin. Dans ces données, le nombre d'employés d'un magasin n'est lié ni à ce que coûte son personnel, ni à sa surface, ni à ses ventes.

**Conséquence directe pour la suite.** Toute analyse fondée sur le nombre d'employés (productivité par employé, effectif optimal d'un magasin) reposerait sur une variable qui ne signifie rien de mesurable. Pour raisonner sur le personnel, il faut utiliser les **charges de personnel**, qui suivent les ventes. De plus, la table des employés de Contoso ne contient aucune clé vers une boutique : on ne peut pas reconstituer le personnel d'un magasin par une autre voie.

## 7.4 Ce que le projet peut conclure, et ce qu'il ne peut pas

| Analyse | Possible ? | Pourquoi |
|---|---|---|
| Chiffre d'affaires, marge et résultat par boutique, produit, période | Oui | Les montants sont complets et égaux au plan stratégique |
| Usure et renouvellement du catalogue | Oui | Les dates de mise en vente sont renseignées pour tous les produits |
| Coût des remises et de la publicité | Oui | Montants certains |
| Effet d'une remise sur la taille d'une ligne | En partie | Comparaison possible à produit et mois égaux, mais la règle d'attribution des remises est inconnue |
| Effet d'une promotion sur le nombre de ventes | Non | Promotions générales et calées sur le calendrier : aucun groupe témoin |
| Effet de la publicité sur les ventes | Non | La publicité ne varie ni entre boutiques, ni entre catégories, ni d'une année à l'autre |
| Effet du prix sur les ventes | Non | Aucun prix ne change en deux ans |
| Panier moyen, nombre de clients, fidélité | Non | Ni client ni ticket : une ligne est un cumul journalier |

| Analyse | Possible ? | Pourquoi |
|---|---|---|
| Productivité ou effectif optimal par employé | Non | L'effectif n'est cohérent avec aucune autre variable |
| Causes des retours | Non | Fréquence uniforme, aucun facteur explicatif |

Nous considérons ces « non » comme des résultats à part entière. Dire qu'une question ne peut pas recevoir de réponse avec ces données, et le prouver, vaut mieux qu'une réponse fragile. La seconde partie du document applique cette grille question par question.

SECONDE PARTIE · LIVRABLE 4

# Analyse et conclusions

## 8. Méthode de l'analyse

Cette seconde partie répond aux cinq questions de recherche du projet (notebooks 06 à 09). Elle s'appuie sur la table propre et sur les limites établies dans la première partie.

### 8.1 Les questions

| | Question de recherche | Section |
|---|---|---|
| Q1 | Quels sont les facteurs déterminants de la performance des ventes ? | 9 et 10 |
| Q2 | Quel est l'effet des promotions sur le volume et la marge en valeur ? | 11 |
| Q3 | Quels sont les patterns de retour de produits ? | 13 |
| Q4 | Existe-t-il une corrélation entre les remises et le taux de retour ? | 13 |
| Q5 | Quels niveaux de remise maximisent la marge ? | 12 |

### 8.2 Les règles de lecture

Quatre règles s'appliquent à toute l'analyse.

- **Une valeur p ne suffit jamais.** Avec 376 234 lignes, presque tout écart est « statistiquement significatif », même sans aucun intérêt pratique. Chaque test est donc lu sur deux critères : la valeur p (l'écart est-il réel ?) et la taille de l'effet (compte-t-il ?).
- **Le seuil est corrigé quand on multiplie les tests.** Le seuil de 5 % est divisé par le nombre de tests du notebook (correction de Bonferroni), pour ne pas trouver un effet par simple accumulation d'essais. Au total, 56 tests sont inscrits dans des registres : 11 sur le catalogue, 11 sur les promotions, 19 sur les retours et 15 sur les remises.
- **Un test qui ne trouve rien ne prouve pas qu'il n'y a rien.** Pour conclure qu'une action ne rapporte pas, nous nous appuyons sur des intervalles de confiance, qui disent jusqu'où l'effet peut aller.
- **Une corrélation ne dit pas le sens de la cause.** Chaque fois qu'un lien peut s'expliquer autrement, par la saison surtout, nous le disons et nous cherchons une comparaison qui neutralise cette autre explication.

### 8.3 Les méthodes employées

| Méthode | Ce qu'elle fait | Où et pourquoi |
|---|---|---|
| Rapport de corrélation ($\eta^2$) | Mesure la part de la variation expliquée par un facteur à catégories | Q1 : classer les facteurs par leur poids, plutôt que par une valeur p |

| Méthode | Ce qu'elle fait | Où et pourquoi |
|---|---|---|
| Corrélations de Pearson et de Spearman | Lien entre deux variables numériques. Spearman travaille sur les rangs et résiste aux valeurs extrêmes | Q1, Q5 : quand les deux s'accordent, le lien est solide |
| Test de Wilcoxon apparié | Compare deux mesures prises sur la même unité | Catalogue, Q2, Q5 : chaque produit est comparé à lui-même |
| Tests de Kruskal-Wallis et de Friedman | Comparent plus de deux groupes sans supposer de loi normale | Catalogue, Q5 : niveaux de remise, catégories |
| Test du khi-deux et V de Cramér | Lien entre un événement et un facteur, avec sa taille d'effet | Q3 : fréquence des retours par facteur |
| Différence de différences, avec dates et magasins placebo | Compare l'évolution d'un groupe à celle d'un autre | Q2 : seule façon d'approcher un effet sans groupe témoin |
| Régression logistique | Mesure un lien à autres facteurs égaux | Q4 : la remise joue-t-elle encore, une fois la taille de la ligne contrôlée ? |
| Scores z en entonnoir | Dit si un écart dépasse ce que donnerait le hasard, selon le nombre d'observations | Q3 : repérer de vrais produits à problème |
| Centrage par boutique et par mois | Retire la moyenne de la boutique et celle du mois | Q5 : comparer à saison égale |
| Rééchantillonnage (bootstrap) | Recalcule un résultat sur des milliers d'échantillons tirés au hasard | Q5 : donner une fourchette à un gain de marge |

# 9. Q1 : les facteurs déterminants de la performance des ventes

## 9.1 Vue d'ensemble

| | 2020 | 2021 | Deux années |
|---|---|---|---|
| Chiffre d'affaires net des retours | 759,1 M$ | 688,2 M$ | 1 447,3 M$ |
| Marge nette des retours | | | 813,3 M$, soit 56 % du chiffre d'affaires |
| Résultat d'exploitation | | | 326,3 M$, soit 163,1 M$ par an |
| dont les 54 magasins | | | 2,2 M$, soit 1,1 M$ par an |

Le chiffre d'affaires est le produit de trois quantités : le nombre de lignes, les unités par ligne et le prix moyen par unité. Entre 2020 et 2021, il recule de 9 % sous l'effet de trois mouvements qui se compensent en partie : moins de lignes (environ −19 %), des lignes plus grosses (environ +44 % d'unités), et des unités moins chères en moyenne (environ −22 %). Comme aucun prix ne change, la baisse du prix moyen ne peut venir que du **mix de produits** : en 2021, on vend relativement plus de produits bon marché.

## 9.2 Le temps

- **Une saisonnalité existe, mais elle est inattendue.** Janvier est le mois le plus faible (70 à 75 % d'un mois moyen), l'activité est élevée de février à juillet, puis recule d'août à décembre. Il n'y a **aucun pic de fin d'année**, alors que la promotion des Fêtes est la plus forte. C'est le contraire de ce qu'on observe dans le commerce de détail.
- **Le jour de la semaine ne joue aucun rôle**, et **les jours fériés non plus** : sur 38 501 observations magasin et jour, la corrélation entre jour férié et chiffre d'affaires est de −0,006.

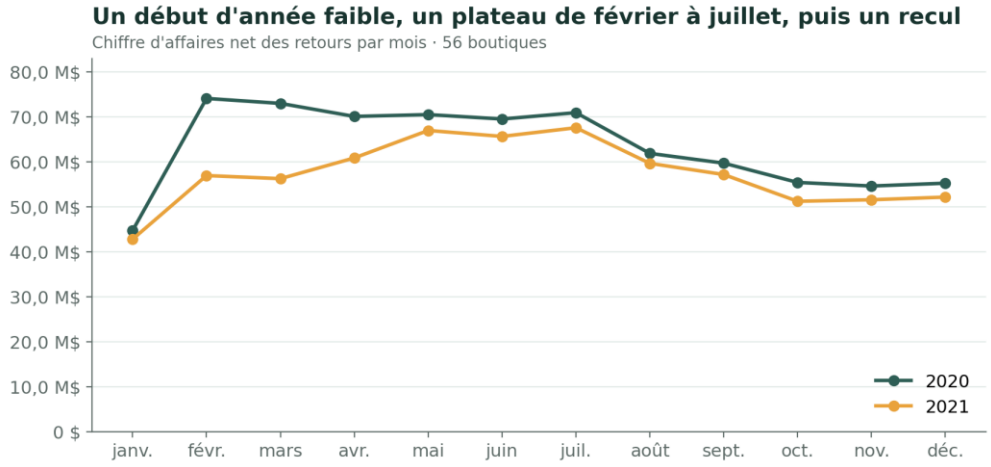



*Figure 4. Un début d'année faible, un plateau de février à juillet, puis un recul*

## 9.3 Les produits

- **Deux catégories dominent** : Home Appliances et Computers font près de 60 % du chiffre d'affaires. Avec Cameras and camcorders, on atteint près de 80 %.
- **Le taux de marge varie peu d'une catégorie à l'autre** (de 52 % à 60 %). Ce qui fait la marge d'une catégorie, c'est son volume.
- **La gamme, elle, joue sur le taux de marge** : environ 49 % en économique, 54 % en standard et 66 % en luxe. Le luxe fait un quart du chiffre d'affaires et près de 30 % de la marge.
- **La concentration est modérée** : il faut 41 % des produits pour faire 80 % des ventes. Aucun produit vedette dont tout dépendrait.

## 9.4 Les boutiques

- **La taille change tout entre les types.** La boutique en ligne et le revendeur font à eux deux 60 % des ventes, chacun l'équivalent de plusieurs dizaines de magasins. En revanche, le taux de marge est le même partout (56 %), et le mix de catégories aussi.
- **Les magasins se ressemblent beaucoup.** Un seul se détache nettement : Moscow No.2, qui vend deux fois et demie plus que les autres.
- **Le pays ne joue presque pas, la surface pas du tout, l'effectif très peu.** Un magasin deux fois plus grand ne vend pas plus.

## 9.5 Le poids de chaque facteur

Pour classer les facteurs, nous mesurons la part de la variation du chiffre d'affaires que chacun explique à lui seul ($\eta^2$).

| Facteur | Part expliquée du montant d'une ligne | Lecture |
|---|---|---|
| Produit | 88,6 % | Savoir quel produit est vendu suffit presque à connaître le montant |
| Sous-catégorie | 64,4 % | |
| Marque | 19,7 % | |
| Gamme | 17,7 % | |
| Catégorie | 14,4 % | |
| Promotion (laquelle) | 2,5 % | |
| Année, mois | 1,5 % chacun | |
| Boutique, type de boutique | 0,3 % chacun | Une ligne du même produit rapporte la même chose partout |
| Promotion (oui ou non), pays | 0,2 % et 0,1 % | |
| Jour de la semaine, jour férié | 0,0 % | |

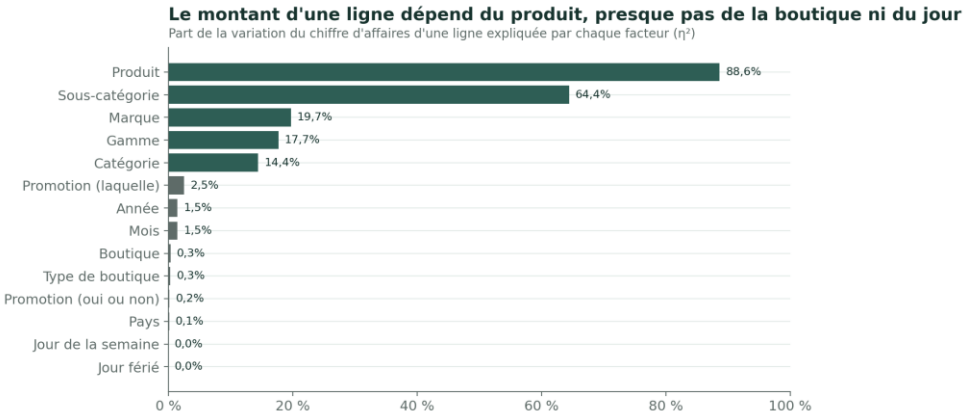



*Figure 5. Le montant d'une ligne dépend du produit, presque pas de la boutique ni du jour*

Au niveau du mois, pour les magasins, la boutique semble expliquer la moitié des écarts (53 %). Mais cet effet vient presque entièrement de Moscow No.2 : sans lui, la boutique n'explique plus que 9 % et le pays moins de 1 %. C'est alors le calendrier qui domine, avec le mois de l'année (environ 38 %) et l'année (environ 20 %).

**Les corrélations entre variables numériques**, calculées par magasin et par mois, complètent ce classement.

- Le chiffre d'affaires d'un magasin est lié à son **nombre de lignes** (Spearman +0,51) et à son **chiffre d'affaires par ligne** (+0,52).

- Il est lié **négativement** au taux de remise effectif (−0,59). Cela ne prouve pas que les promotions font baisser les ventes : elles suivent le calendrier. La section 12 montre que ce lien disparaît à saison égale.
- Le **résultat d'exploitation** d'un magasin est d'abord l'image inversée de sa dépense de publicité : corrélation de Pearson de −0,91, la plus forte de toute la matrice.
- La surface, la sévérité du COVID-19 et le taux de retour n'ont aucun lien notable avec les ventes.

**Réponse à la partie « ventes » de Q1.** Le chiffre d'affaires se construit en deux étages. Le **produit** fixe ce que rapporte une ligne. Le **nombre de lignes**, qui dépend du type de boutique et de la période, fixe combien de fois cela se produit. La boutique en tant que telle ne joue pas.

## 9.6 Pourquoi les ventes baissent : le catalogue vieillit

**Où se trouve la baisse.** Le premier trimestre 2021 concentre la moitié de la baisse de l'année (−35,8 M$ sur −70,9 M$). Deux catégories la portent presque entièrement : Home Appliances (−20,7 M$) et Cameras and camcorders (−14,6 M$). Les trois types de boutiques sont touchés. Une rupture nette apparaît au 1er janvier 2021 : le nombre de lignes passe d'environ 18 000 par mois à environ 13 000 et reste à ce niveau.

**Les explications habituelles sont écartées.** Les prix n'ont pas changé. Les promotions et la publicité suivent le même calendrier les deux années. Toutes les boutiques sont touchées. Le COVID-19 n'a aucun effet mesurable. Il reste une piste : les produits eux-mêmes.

**L'idée, en une image.** Un catalogue fonctionne comme un seau percé qu'on remplit au robinet. Chaque année, les produits déjà en vente perdent une partie de leurs ventes : c'est la fuite. Chaque année aussi, de nouveaux produits arrivent : c'est le robinet. Le chiffre d'affaires baisse quand la fuite dépasse le robinet.

Chaque produit a une date de mise en vente. Nous séparons donc le **catalogue en place** (produits lancés en 2020 ou avant) des **nouveautés** (lancées en 2021).

| | 2020 | 2021 | Écart |
|---|---|---|---|
| Catalogue en place (2 244 produits) | 759,1 M$ | 607,1 M$ | **−151,9 M$** (−20 %) |
| Nouveautés de 2021 (264 produits) | 0 | 81,1 M$ | **+81,1 M$** |
| Ensemble | 759,1 M$ | 688,2 M$ | −70,9 M$ (−9,3 %) |

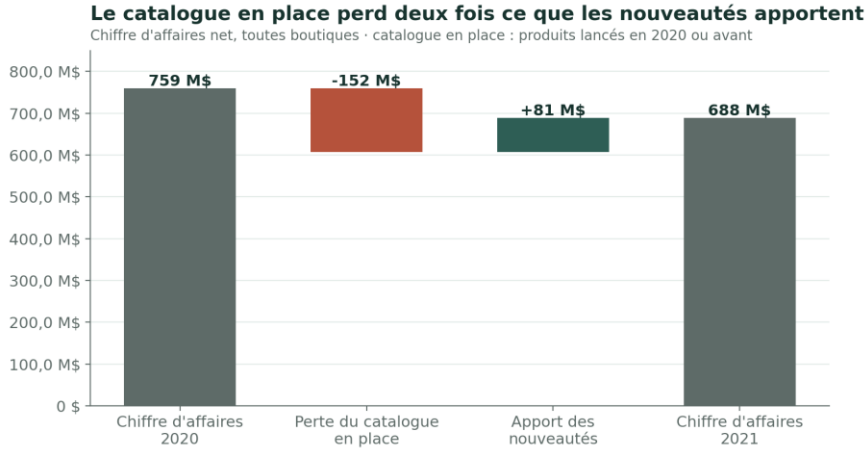



*Figure 6. Le catalogue en place perd deux fois ce que les nouveautés apportent*

Les produits déjà au catalogue ont perdu un cinquième de leurs ventes en un an, et les nouveautés ne compensent que 53 % de cette perte. La baisse ne vient donc pas d'un événement de 2021, mais d'un mécanisme permanent : l'usure du catalogue, insuffisamment compensée.

### Ce sont les produits récents qui s'usent le plus vite

| Lancés en | Produits | Évolution des ventes en 2021 | Écart |
|---|---|---|---|
| 2016 | 113 | +53 % | +9,1 M$ |
| 2017 | 503 | −8 % | −11,5 M$ |
| 2018 | 647 | −16 % | −29,0 M$ |
| 2019 | 552 | **−33 %** | **−89,5 M$** |
| 2020 | 429 | −21 % | −31,0 M$ |

Les produits lancés en 2019 étaient les meilleurs vendeurs de 2020. Un an plus tard, ils ont perdu un tiers de leurs ventes et font à eux seuls 59 % de la perte. Un produit a une période forte, juste après son lancement, puis il décline.

### Le renouvellement ne se fait pas là où la perte est la plus forte

| Catégorie | Usure du catalogue en place | Nouveautés | Perte compensée | Solde |
|---|---|---|---|---|
| Home Appliances | −37 % (−99,1 M$) | 54, soit 9 % du catalogue | 36 % | −63,7 M$ |
| Cameras and camcorders | −29 % (−43,6 M$) | 29, soit 8 % | 12 % | −38,4 M$ |
| TV and Video | −20 % (−16,9 M$) | 23, soit 12 % | 71 % | −4,9 M$ |
| Cell phones | −17 % (−7,9 M$) | 36, soit 14 % | 120 % | +1,6 M$ |
| Computers | +8 % (+14,4 M$) | 62, soit 12 % | sans objet | +28,2 M$ |

Home Appliances et Cameras cumulent les deux problèmes : leur catalogue s'use le plus vite, et elles reçoivent le moins de nouveautés. Ces deux catégories expliquent une perte nette de 102 M$, plus que la baisse totale.

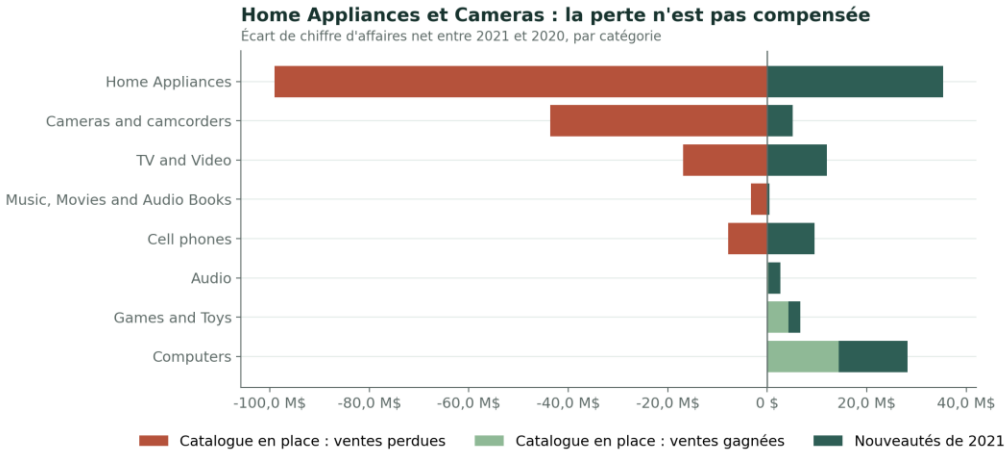



*Figure 7. Home Appliances et Cameras : la perte n'est pas compensée*

### Les magasins sont plus exposés que la boutique en ligne

| Type de boutique | Usure du catalogue en place | Part compensée par les nouveautés | Produits différents vendus par boutique et par mois |
|---|---|---|---|
| En ligne | −15 % | 85 % | 1 950 en 2020, 2 118 en 2021 (+9 %) |
| Revendeur | −23 % | 47 % | 1 768, puis 1 765 |
| Magasins | −23 % | 39 % | 153, puis 110 (**−28 %**) |

Un magasin ne vend qu'une petite partie du catalogue chaque mois, et cette partie se réduit : il vend moins de références, sur un catalogue qui s'use, et profite moins des nouveautés.

## 9.7 L'usure du catalogue résiste-t-elle aux tests ?

Le bilan ci-dessus est une addition : il n'y a rien à estimer. Mais il laisse quatre objections, et chacune se teste.

| Objection | Ce que disent les tests |
|---|---|
| « La baisse vient de quelques gros produits » | Non. Le produit **médian** perd 18,7 % de son chiffre d'affaires, presque la baisse d'ensemble. Et 89 % des produits ont moins de lignes de vente en 2021, avec une baisse médiane de 32 % |
| « C'est propre à un type de boutique » | Non, mais l'ampleur diffère : le produit médian garde son chiffre d'affaires en ligne (+0,4 %), recule de 11,6 % chez le revendeur et de **27,9 % en magasin** |
| « Les nouveautés se vendent mal, en lancer davantage ne servirait à rien » | Non. Par mois de présence, une nouveauté rapporte en médiane 13 900 $, un produit en place 14 700 $. L'écart n'est pas significatif ($p = 0,25$). C'est une question de **nombre** : 264 nouveautés pour 2 244 produits en place |

| Objection | Ce que disent les tests |
|---|---|
| « Rien ne prouve que renouveler davantage fait vendre davantage » | Entre les 32 sous-catégories, le taux de renouvellement et l'évolution des ventes sont liés nettement (ρ = +0,55, p = 0,001, significatif après correction) |

Les sous-catégories qui se renouvellent peu (7 % de nouveautés en médiane) voient leurs ventes reculer de 16 %. Celles qui se renouvellent beaucoup (20 %) les voient progresser de 16 %.

**Pas de cannibalisation.** Si les nouveautés prenaient leurs ventes aux produits en place, le catalogue en place reculerait davantage là où il y a beaucoup de nouveautés. Nous observons le contraire. Les nouveautés s'ajoutent, elles ne remplacent pas.

**Une exception à signaler.** Les ordinateurs portables doublent leurs ventes sans aucune nouveauté. Le renouvellement n'est donc pas la seule cause possible d'une hausse.

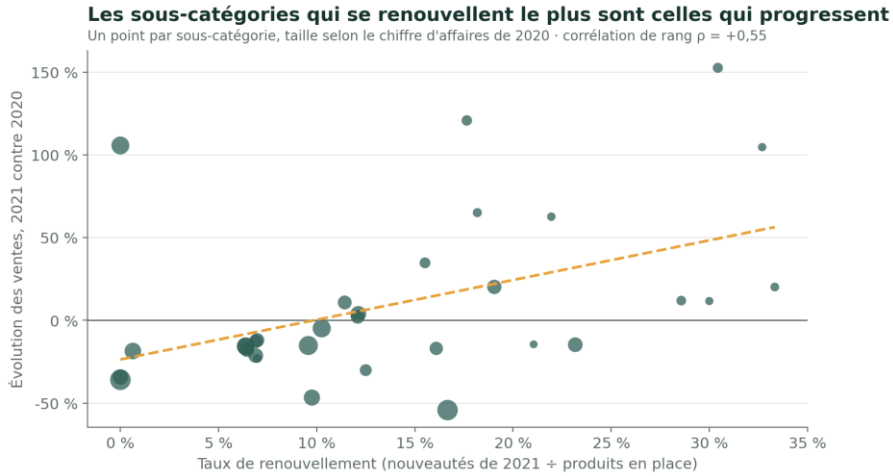



*Figure 8. Les sous-catégories qui se renouvellent le plus sont celles qui progressent*

# 10. Q1, suite : la rentabilité après charges et les leviers

Jusqu'ici la marge s'arrêtait au coût des produits. Le plan stratégique permet d'aller plus loin et de retirer les frais généraux et la publicité de chaque boutique. La question change : non plus « qui vend le plus », mais « qui gagne vraiment de l'argent ».

## 10.1 Ce que deviennent 100 $ de ventes

| Type de boutique | Coût des produits | Frais généraux | Publicité | Résultat d'exploitation |
|---|---|---|---|---|
| En ligne | 43,9 $ | 17,9 $ | 0,5 $ | **37,7 $** |
| Revendeur | 43,9 $ | 19,8 $ | 0,8 $ | **35,6 $** |
| Magasins | 43,7 $ | 32,8 $ | 23,2 $ | **0,4 $** |

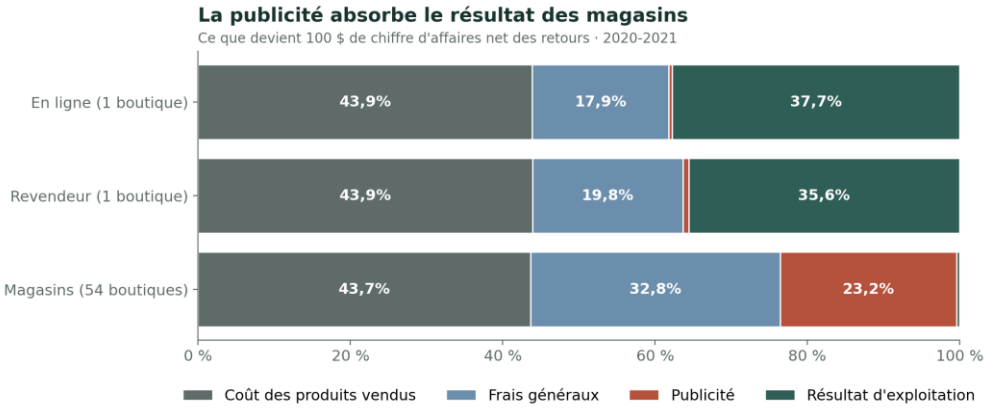



*Figure 9. La publicité absorbe le résultat des magasins*

- **Avant publicité, tous les types de boutiques gagnent de l'argent.**
- **La publicité fait basculer les magasins** : elle absorbe presque tout ce qui leur reste. Seuls 9 magasins sur 54 sont bénéficiaires.
- **Ce n'est pas le chiffre d'affaires qui sépare les gagnants des perdants, c'est le taux de frais généraux.** Les 8 magasins au taux bas sont tous bénéficiaires. Sur les 46 au taux haut, 45 sont déficitaires, pour un chiffre d'affaires médian voisin.
- **Les retours ne sont pas en cause** : même sans aucun retour, le résultat des magasins resterait proche de zéro.

## 10.2 Le déficit des magasins est saisonnier

Le déficit est concentré sur janvier, février et mars, les mois où le plan concentre 86 % du budget publicitaire des magasins. Le reste de l'année, les magasins sont bénéficiaires tous les mois.

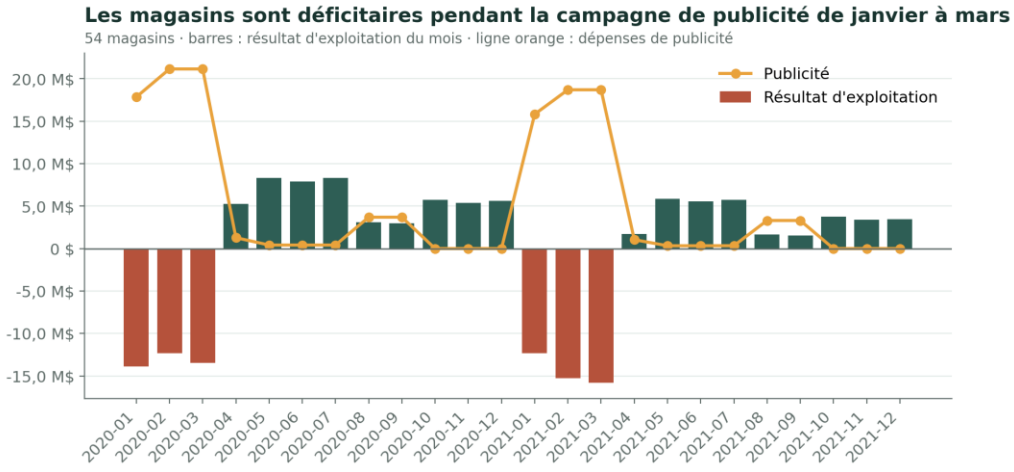



*Figure 10. Les magasins sont déficitaires pendant la campagne de publicité de janvier à mars*

Par catégorie, les magasins gagnent de l'argent sur Computers et en perdent sur Home Appliances et Cameras and camcorders, deux grosses catégories pourtant rentables en marge. En ligne et chez le revendeur, toutes les catégories sont rentables.

## 10.3 Le détail des charges

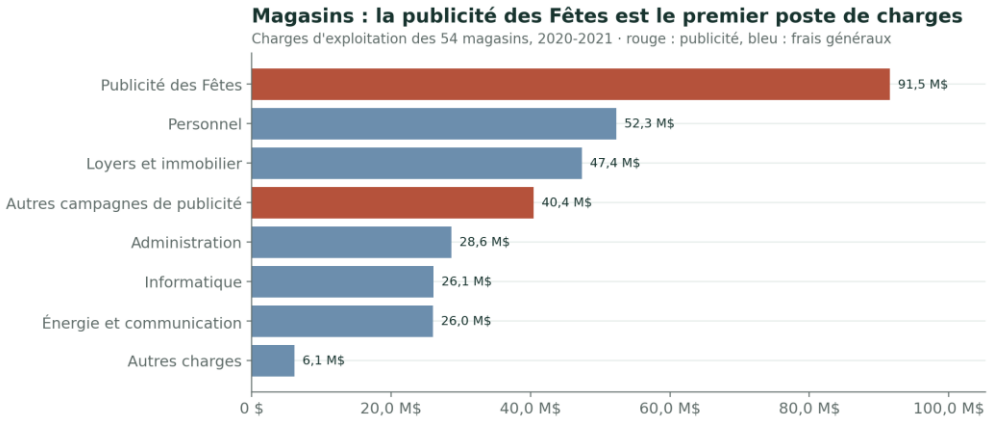



*Figure 11. Dans les magasins, la publicité des Fêtes est le premier poste de charges*

- **Frais généraux (350 M$ en deux ans).** Le personnel (97 M$) et les loyers (89 M$) font plus de la moitié. Les magasins paient presque le double de la boutique en ligne sur chaque compte, dans la même proportion : il n'y a donc pas un poste qui expliquerait leur surcoût.
- **Publicité (137 M$).** La campagne des Fêtes en représente 69 %. Elle est dépensée de janvier à mars, donc **après** les Fêtes, alors que la promotion correspondante court d'octobre à janvier. 96 % de la publicité est imputée aux magasins, parce que chaque boutique reçoit le même montant.
- **L'effet de la publicité n'est pas mesurable.** Elle ne varie ni entre boutiques, ni entre catégories, et son calendrier est le même les deux années. Le premier poste de charges des magasins est celui dont on ne peut rien dire de l'efficacité.

## 10.4 Charges fixes et charges variables

Dans le plan, les cinq grands comptes de frais généraux réagissent tous de la même façon aux ventes, loyers compris. Ce n'est pas réaliste. Nous retenons donc une classification fondée sur la nature de chaque charge.

| Charge | Nature | Pourquoi |
|---|---|---|
| Personnel | Fixe, ajustable par décision | Le personnel de terrain ne baisse pas tout seul quand les ventes baissent. C'est la direction qui ajuste |
| Administration, informatique | Fixe, mutualisable | Travail de bureau, indépendant des ventes, regroupable à l'échelle d'un pays |
| Loyers et immobilier | Fixe, subi | Baux : ils ne suivent pas les ventes |
| Énergie et communication | Fixe, subi | Dépend de prix que l'entreprise ne maîtrise pas |
| Autres charges, impôts | Variable | Proportionnels aux ventes dans le plan |

Conséquence : un dollar de vente perdu en magasin coûte 0,44 $. Ce chiffre sert à calculer tous les seuils qui suivent.

## 10.5 Les charges ont augmenté pendant que les ventes baissaient

Sur les 51 magasins ouverts les deux années :

| Compte | 2020 | 2021 | Évolution | En part des ventes |
|---|---|---|---|---|
| **Ventes** | 305,7 M$ | 257,8 M$ | **−15,7 %** | |
| Personnel | 24,8 M$ | 26,8 M$ | +8,1 % | 8,1 %, puis 10,4 % |
| Administration | 13,1 M$ | 15,1 M$ | +15,0 % | 4,3 %, puis 5,9 % |
| Informatique | 12,4 M$ | 13,4 M$ | +8,1 % | 4,0 %, puis 5,2 % |
| Loyers et immobilier | 23,0 M$ | 23,7 M$ | +3,2 % | 7,5 %, puis 9,2 % |
| Énergie et communication | 12,4 M$ | 13,3 M$ | +8,0 % | 4,0 %, puis 5,2 % |
| Autres charges | 3,2 M$ | 2,7 M$ | −15,3 % | 1,1 % |
| Impôts et taxes | 32,9 M$ | 27,8 M$ | −15,5 % | 10,8 % |

Les 51 magasins sont concernés, sans exception. Ce n'est pas le problème de quelques magasins mal gérés : c'est une hausse générale des charges fixes pendant que l'activité reculait.

**La réponse, en deux temps**, sur les comptes que l'entreprise maîtrise (personnel, administration, informatique) :

| Étape | Objectif | Gain par an |
|---|---|---|
| 1. Priorité | Revenir au montant de 2020 : annuler la hausse | 5,0 M$ |
| 2. Ensuite | Garder ces charges proportionnelles au chiffre d'affaires : règle de gestion à tenir dans la durée | 12,9 M$, étape 1 comprise |

Les loyers et l'énergie sont constatés, pas corrigés : leur hausse tient à des baux et à des prix que l'entreprise subit. Le personnel de terrain est le levier que nous proposons de toucher le moins : pour lui, la proportionnalité se retrouve de préférence par la reprise des ventes.

## 10.6 Une piste : regrouper l'administration et l'informatique par pays

Dans un pays qui compte plusieurs magasins, un seul bureau au lieu d'un par magasin. Sur place restent trois coordinateurs (contrôle de gestion, informatique, ressources humaines), au coût d'un employé moyen : ce sont des coordinateurs, pas des cadres. Un petit magasin proche d'un plus grand n'en garde pas.

Le calcul repose sur le socle fixe d'un bureau, estimé en comparant les magasins : 231 470 $ par an, plus 5,1 % des ventes. L'économie d'un pays vaut le socle des bureaux supprimés, moins le coût des coordinateurs conservés.

Résultat : **7,3 M$ par an**, dont 2,7 M$ au Royaume-Uni, 2,0 M$ en Allemagne, 1,3 M$ en France, 0,8 M$ en Italie et 0,6 M$ en Russie. Les douze pays qui n'ont qu'un magasin ne sont pas concernés. C'est une piste de réflexion à confier aux gens du métier, et elle recoupe en partie l'étape 2 : les deux ne s'additionnent pas.

## 10.7 La publicité : une grille plutôt qu'une prévision

Comme l'effet de la publicité sur les ventes est inconnu, nous donnons le résultat dans chaque cas. Résultat d'exploitation annuel des 54 magasins, aujourd'hui de 1,1 M$ :

| Ventes des magasins | Publicité −5 % | Publicité −10 % | Publicité −20 % |
|---|---|---|---|
| Inchangées | 4,4 M$ | 7,7 M$ | 14,3 M$ |
| −2 % | 1,9 M$ | 5,2 M$ | 11,8 M$ |
| −5 % | −1,9 M$ | 1,4 M$ | 8,0 M$ |
| −8 % | −5,7 M$ | −2,4 M$ | 4,2 M$ |
| −10 % | −8,2 M$ | −4,9 M$ | 1,7 M$ |

Une baisse de 10 % de la publicité multiplie par sept le résultat des magasins si les ventes tiennent, et reste gagnante jusqu'à environ 5 % de ventes perdues. Pour que la publicité actuelle soit justifiée, il faudrait que 10 % de publicité en plus apportent au moins 5,2 % de ventes en plus. Or la boutique en ligne et le revendeur vendent autant avec cinquante fois moins de publicité.

## 10.8 Les leviers de rentabilité, par an

Résultat d'exploitation actuel : 163,1 M$ par an.

| | Levier | Gain par an | Résultat après | Seuil |
|---|---|---|---|---|
| 1 | Renouveler le catalogue : retrouver le chiffre d'affaires de 2020 | 31,3 M$ | 194,5 M$ | |
| 2 | Baisser la publicité des magasins de 20 % | 13,2 M$ | 176,3 M$ | 10,5 % |
| 3 | Charges proportionnelles aux ventes (étape 2) | 12,9 M$ | 176,0 M$ | |
| 4 | Regrouper administration et informatique par pays | 7,3 M$ | 170,4 M$ | |
| 5 | Baisser la publicité des magasins de 10 % | 6,6 M$ | 169,7 M$ | 5,2 % |
| 6 | Supprimer les remises en magasin | 6,0 M$ | 169,1 M$ | |
| 7 | Revenir aux charges de 2020 (étape 1) | 5,0 M$ | 168,1 M$ | |
| 8 | Baisser la publicité des magasins de 5 % | 3,3 M$ | 166,4 M$ | 2,6 % |
| 9 | Réduire les retours de moitié | 2,8 M$ | 165,9 M$ | |
| 10 | Déplacer 1 % des ventes de la gamme économique vers la gamme luxe | 1,2 M$ | 164,3 M$ | |

Le seuil est la baisse des ventes qu'on peut supporter en restant au moins aussi rentable qu'aujourd'hui. Il n'existe que pour les leviers qui risquent de faire baisser les ventes.

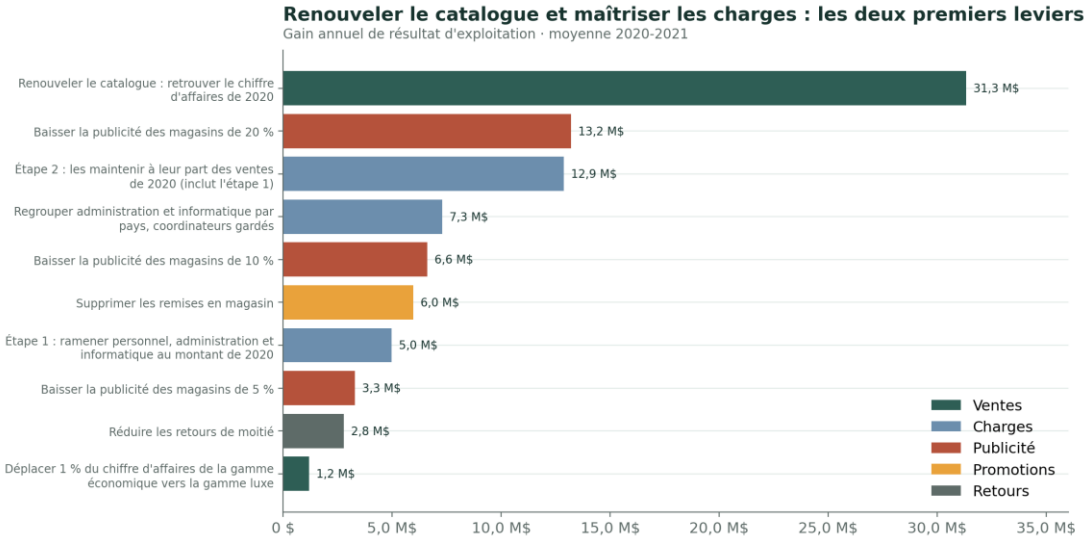



*Figure 12. Renouveler le catalogue et maîtriser les charges : les deux premiers leviers*

**Comment lire ce tableau.** Ce sont des ordres de grandeur pour orienter la réflexion, pas des décisions. Chaque ligne dit ce qu'un levier pourrait rapporter si l'hypothèse qui le porte se vérifie. Le choix et la mise en œuvre reviennent aux gens du métier.

**Ce classement contredit l'idée de départ.** Nous nous attendions à ce que les promotions et les retours soient les grands sujets. Les deux premiers leviers sont ailleurs.

- **Le renouvellement du catalogue** est le seul grand levier qui agit sur les ventes et non sur les dépenses. C'est aussi le plus difficile : il ne se décide pas, il se construit. Son gain est brut, le coût des lancements n'étant pas dans les données.
- **La maîtrise des charges**, publicité comprise, est une décision de gestion, rapide à mettre en œuvre.

Ces deux leviers se complètent : les économies du second financent le temps que demande le premier.

**Réponse à Q1.** La performance des ventes dépend de ce qu'on vend et de combien de fois on le vend. Le produit fixe le montant d'une ligne, le type de boutique et la période fixent le nombre de lignes. La boutique elle-même (pays, surface, effectif) ne compte pas. La baisse de 2021 vient de l'usure du catalogue. La rentabilité, elle, se joue après la marge : sur les frais généraux, et surtout sur la publicité.

# 11. Q2 : l'effet des promotions

## 11.1 Comment les promotions sont distribuées

- **Elles sont générales** : un mois donné, tous les produits de toutes les boutiques sont sous la même promotion.
- **Elles suivent un calendrier fixe**, identique en 2020 et en 2021, neuf mois sur douze : 20 % d'octobre à janvier, 7 % de février à avril, aucune de mai à juillet, 10 % en août et septembre.
- **Un seul magasin fait exception** : Cambridge suit le calendrier des promotions « North America », à d'autres dates.

- **La remise réelle est bien plus faible que le taux annoncé** : 4,8 % du montant pour une promotion « à 20 % ».

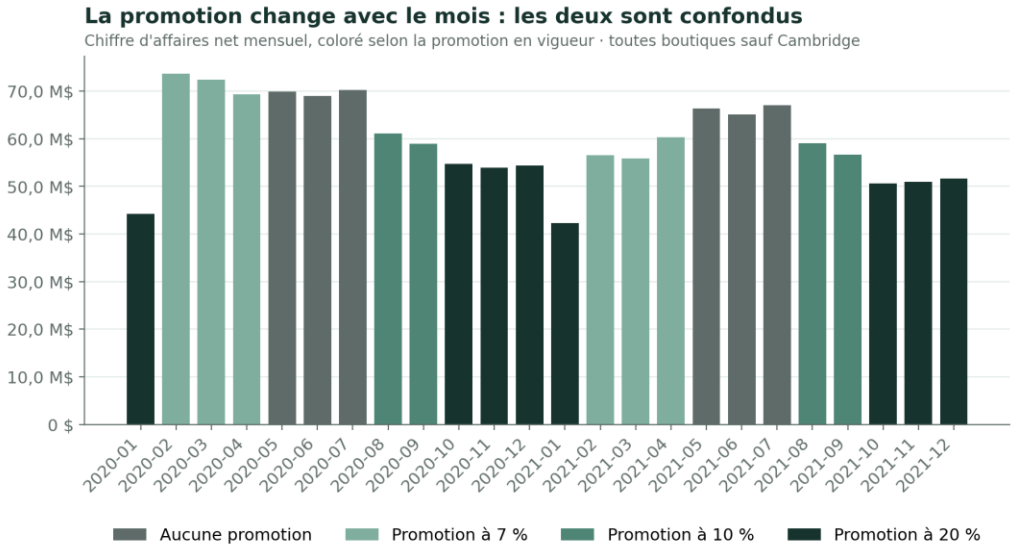



*Figure 13. Le calendrier des promotions, identique les deux années*

## 11.2 Le piège : promotion et saison sont confondues

Dans une enseigne réelle, une promotion vise quelques produits ou quelques magasins, et les autres servent de groupe témoin. Ici, il n'y en a pas. Comparer « avec » et « sans » promotion revient à comparer mai, juin et juillet au reste de l'année.

La comparaison directe donne d'ailleurs un résultat absurde : les ventes par jour sont **plus faibles de 17 %** sous promotion. Cela ne veut pas dire que les promotions font baisser les ventes, mais que les mois sans promotion sont les meilleurs de l'année.

## 11.3 Trois angles pour contourner le problème

Aucun n'est une preuve à lui seul. C'est leur accord qui fait la conclusion.

| Angle | Idée | Résultat | Solidité |
|---|---|---|---|
| A. Changements de promotion | Comparer les 14 jours avant et après chaque changement de taux : la saison ne change pas en 28 jours | Quand le taux monte, les ventes **baissent** de 10 %. Quand il baisse, elles montent de 24 %. Quand il ne change pas, elles sont stables (−1 %) | Significatif date par date. Lien d'ensemble négatif ($\rho = -0{,}57$), juste à la limite du seuil corrigé |
| B. Magasin témoin | Cambridge suit un autre calendrier : le comparer aux autres le même mois | Il ne vend pas plus quand il a davantage de promotion que les autres | Sens concordant avec A. Non significatif : un seul magasin |
| C. Intensité de la remise | Lignes remisées et non remisées du même produit, le même mois | Lignes remisées plus grosses de 17 %, mais avec moins d'unités au plein tarif | Très significatif, mais ne dit rien du nombre de lignes |

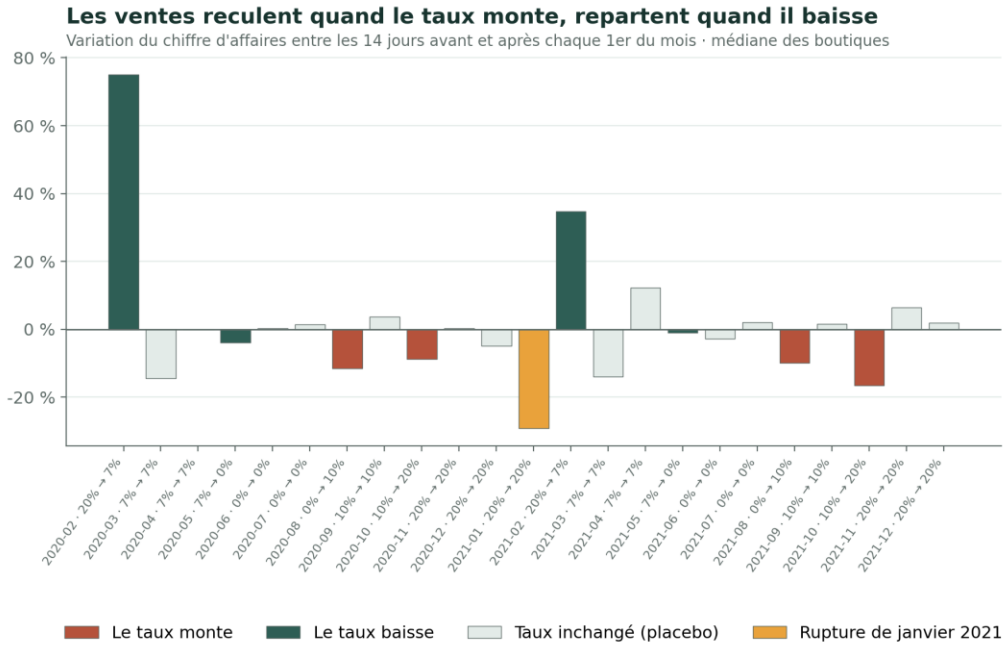



*Figure 14. Les ventes avant et après chaque changement de promotion*

Pour l'angle A, nous avons vérifié que le résultat ne vient pas d'un effet de début de mois, en refaisant le même calcul sur des dates où la promotion ne change pas.

## 11.4 Ce que coûtent les promotions

| Taux annoncé | Remises accordées en deux ans | Taux réel | Hausse des ventes nécessaire pour les compenser |
|---|---|---|---|
| 7 % | 3,3 M$ | 0,8 % | +1,5 % |
| 10 % | 5,4 M$ | 2,2 % | +3,9 % |
| 20 % | 20,8 M$ | 4,8 % | +9,1 % |
| Ensemble | 29,4 M$ | | |

Les seuils sont bas : une promotion qui fonctionne les dépasse facilement. Or aucune hausse n'est observée. À titre de comparaison, la publicité des magasins pèse onze fois plus que leurs remises.

**Réponse à Q2.** Aucun des trois angles ne montre que les promotions augmentent les ventes d'une boutique, et les deux qui mesurent les ventes totales vont dans le sens contraire. Leur coût, lui, est certain : 29,4 M$ en deux ans, dont 71 % pour la seule promotion à 20 %. La section 12 précise ce résultat pour la marge.

**Interprétation métier (hypothèses).** Une promotion sur tout le catalogue, neuf mois sur douze, ne crée pas le sentiment de faire une affaire : une remise générale et quasi permanente devient le prix normal. Un calendrier prévisible peut aussi inciter un client non pressé à attendre. Cette seconde hypothèse est en partie vérifiable : si les clients attendaient, on verrait un creux juste avant une promotion et un pic juste après. L'angle A montre le contraire. Dans une entreprise réelle, des

promotions calées sur les Fêtes devraient faire vendre plus. Ici l'entreprise y vend moins qu'ailleurs : soit elles sont mal conçues, soit elles ne servent à rien. Dans les deux cas, elles sont à repenser.

# 12. Q5 : les niveaux de remise et la marge

## 12.1 Pourquoi nous ne cherchons pas un « taux optimal »

Q5 suggère de trouver le taux qui maximise la marge. Les données ne le permettent pas directement : il n'existe que trois niveaux (7 %, 10 %, 20 %), et chacun est attaché à une période de l'année, la même en 2020 et en 2021. Comparer deux niveaux, c'est aussi comparer deux saisons.

Nous répondons donc à une question plus solide : **à produit égal et à mois égal, une ligne qui reçoit une remise rapporte-t-elle plus de marge qu'une ligne qui n'en reçoit pas, et cela dépend-il du niveau ?**

## 12.2 À saison égale, plus de remise ne fait pas vendre plus

Un mois donné, toutes les boutiques sont sous la même promotion, mais elles n'accordent pas exactement la même remise. Nous retirons de chaque observation la moyenne de sa boutique et la moyenne de son mois. Ce qui reste est l'écart d'une boutique par rapport à ce qu'on attendait d'elle.

| Variable | Corrélation brute avec le taux de remise | À boutique et mois constants |
|---|---|---|
| Nombre de lignes | +0,23 | 0,00 |
| Unités vendues | −0,46 | −0,03 |
| Chiffre d'affaires net | −0,50 | −0,08 |
| Marge en valeur | −0,51 | −0,09 |

Le lien brut, fort et négatif, était un effet de calendrier. À saison égale, il disparaît presque entièrement. Ce qui reste est négatif, jamais positif.

## 12.3 De quoi est faite une ligne remisée

Pendant une promotion, toutes les lignes ne reçoivent pas de remise. Pour un même produit et un même mois, nous comparons les lignes remisées aux autres : seule la remise change. Une remise ne porte que sur peu d'unités, 1 à 4 presque toujours (2,9 en moyenne), quel que soit le niveau.

Toutes boutiques confondues, une ligne remisée contient 2,75 unités remisées, mais 1,8 unité au plein tarif de moins qu'une ligne sans remise. **65 % des unités remisées prennent la place d'unités qui auraient été payées au plein tarif**, et 35 % seulement s'ajoutent.

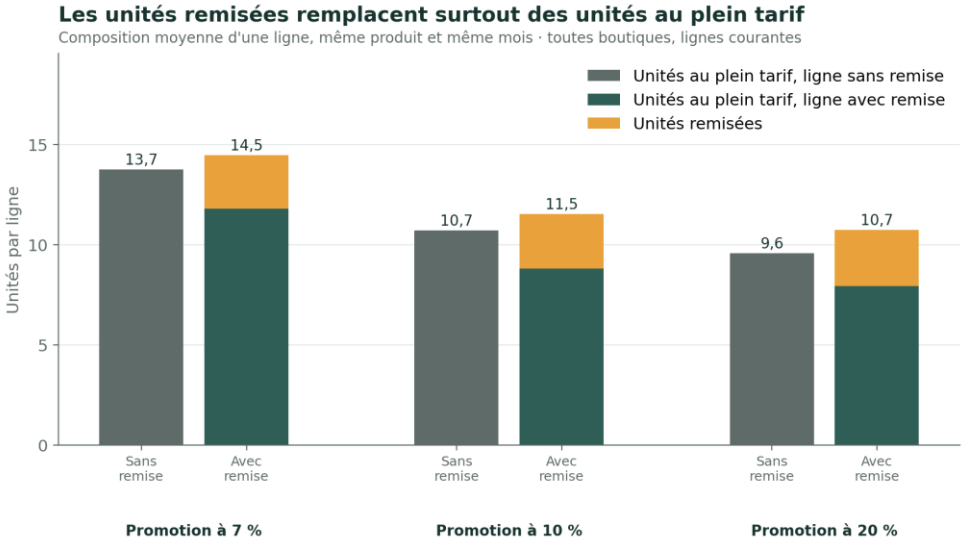



*Figure 15. Les unités remisées remplacent surtout des unités au plein tarif*

La marge donne deux réponses qui divergent : en moyenne, une ligne remisée rapporte 4,5 % de plus, mais le cas médian est à −0,8 %. S'arrêter à la moyenne ferait conclure que la remise est rentable, s'arrêter à la médiane qu'elle est neutre. Aucune des deux lectures n'est juste tant qu'on n'a pas regardé ce qui sépare les lignes.

## 12.4 Deux réalités opposées selon le type de boutique

| | Magasins | En ligne | Revendeur |
|---|---|---|---|
| Unités d'une ligne sans remise | 10,6 | 10,9 | 10,6 |
| Unités d'une ligne avec remise | 10,4 | 13,1 | 12,3 |
| Part des unités remisées qui remplacent du plein tarif | 107 % | 27 % | 41 % |
| Marge d'une ligne remisée, en moyenne | **−8,4 %** | +17,1 % | +10,4 % |
| Intervalle de confiance à 95 % | −8,7 % à −8,0 % | +15,4 % à +18,9 % | +8,6 % à +12,2 % |
| Marge d'une ligne remisée, cas médian | −7,3 % | −1,1 % | −3,2 % |
| Lignes remisées qui rapportent davantage | 14 % | 48 % | 36 % |

**En magasin, la remise est un pur coût.** Une ligne remisée contient le même nombre d'unités qu'une ligne sans remise : les unités remisées remplacent une pour une des unités au plein tarif. Moyenne et médiane sont d'accord. Le résultat tient dans les trois gammes et les huit catégories, sans exception.

**En ligne et chez le revendeur, la moyenne monte mais le cas typique ne bouge pas.** L'explication est dans la taille des lignes : les lignes remisées y sont plus souvent de grosses lignes (16 unités ou plus : 40 % contre 26 % en ligne). Une unité remisée fait gagner de la marge quand elle s'ajoute, puisqu'elle reste vendue au-dessus de son coût, et en fait perdre quand elle remplace une unité au plein tarif.

**Deux lectures restent possibles pour ces deux canaux**, et les données ne tranchent pas. Soit la remise incite une partie des acheteurs à commander de plus grosses quantités. Soit les grosses commandes obtiennent plus facilement une remise, sans que celle-ci les ait provoquées.

## 12.5 Une remise plus forte ne rapporte nulle part davantage

| Gain de marge d'une ligne remisée | Remise à 7 % | Remise à 10 % | Remise à 20 % |
|---|---|---|---|
| Magasins | −4,8 % | −6,6 % | −11,7 % |
| En ligne | +16,6 % | +18,6 % | +16,7 % |
| Revendeur | +13,6 % | +11,5 % | +7,8 % |

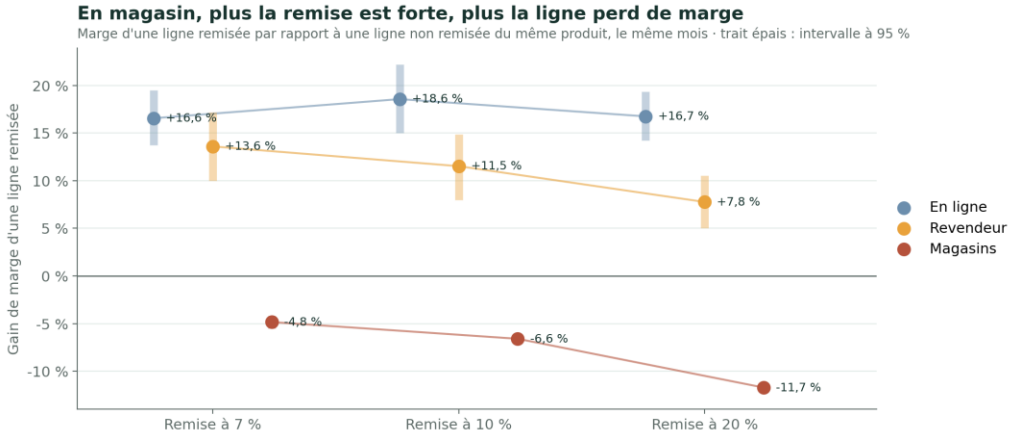



*Figure 16. En magasin, plus la remise est forte, plus la ligne perd de marge*

- **Magasins** : le niveau compte, et dans le mauvais sens. La différence entre niveaux est massive, produit par produit.
- **En ligne** : le niveau ne compte pas (p = 0,66). Une remise à 20 % ne rapporte pas plus qu'une remise à 7 %, alors qu'elle coûte près de trois fois plus par unité remisée. Cette absence de lien entre la dose et l'effet est un argument contre l'idée que la remise soit la cause des grosses lignes.
- **Revendeur** : tendance à la baisse, non confirmée par les tests.

## 12.6 Chaque décision, bornée par deux lectures

Comme nous ne savons pas si les unités en plus d'une ligne remisée viennent de la remise, chaque décision est encadrée par deux hypothèses. Dans la lecture A, les lignes resteraient les mêmes sans remise : on récupère le montant des remises. Dans la lecture B, une ligne sans remise ressemblerait aux lignes non remisées : on perd ou on gagne l'écart de marge mesuré.

| Décision | Lecture A | Lecture B | Verdict |
|---|---|---|---|
| Supprimer les remises en magasin | +6,0 M$ | +7,1 M$ | **Gain dans les deux cas** |
| Supprimer les remises chez le revendeur | +3,4 M$ | −4,7 M$ | Indéterminé |

| Décision | Lecture A | Lecture B | Verdict |
|---|---|---|---|
| Supprimer les remises en ligne | +5,4 M$ | −12,2 M$ | Indéterminé |
| Ramener de 20 % à 7 % en magasin | +2,7 M$ | +2,7 M$ | Gain |
| Ramener de 20 % à 7 % chez le revendeur | +1,5 M$ | +1,2 M$ | Gain probable |
| Ramener de 20 % à 7 % en ligne | +2,5 M$ | −0,1 M$ | Faible ou nul |

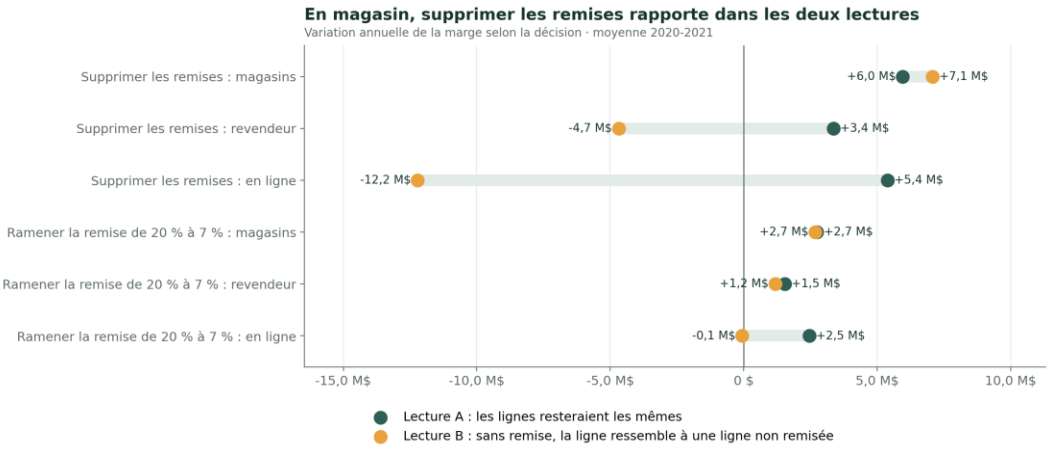



*Figure 17. En magasin, supprimer les remises rapporte dans les deux lectures*

**C'est cette comparaison qui remplace la recherche d'un « non-effet ».** Nous ne prouvons pas qu'une remise n'a aucun effet : nous montrons que, même dans la lecture la plus favorable à la remise, la décision reste la même pour les magasins.

**Réponse à Q5.** La question n'a pas une réponse unique. En magasin, aucun niveau ne maximise la marge : le meilleur est l'absence de remise, et chaque niveau coûte d'autant plus qu'il est élevé. En ligne et chez le revendeur, s'il faut une remise, la plus basse suffit probablement, mais l'effet lui-même n'est pas établi. Nulle part le niveau à 20 %, qui pèse 71 % du coût des remises, n'est justifié par une mesure.

## Recommandations

| | Recommandation | Gain annuel | Statut |
|---|---|---|---|
| 1 | Arrêter les remises générales dans les 54 magasins | 6,0 à 7,1 M$ | Appuyée par les données. C'est aussi le test de l'hypothèse : si les ventes tiennent, elle est confirmée |
| 2 | Repenser la promotion plutôt que la reconduire : ciblée sur quelques produits, limitée dans le temps, moins prévisible, mesurée avec un groupe témoin | non chiffrable | Recommandation de conception |
| 3 | En ligne et chez le revendeur, ne rien changer sans essai, puis tester 7 % à la place de 20 % sur une partie des produits | 1,1 à 4,0 M$ si l'essai est concluant | Piste à tester |

Une promotion ciblée peut aussi servir le premier levier de l'entreprise : lancer les nouveautés, ou écouler les produits en fin de vie.

# 13. Q3 et Q4 : les retours

## 13.1 À quoi ressemble un retour

- **Fréquent mais minuscule** : 14,6 % des lignes ont un retour, soit une ligne sur sept, mais d'une seule unité dans 97 % des cas (jamais plus de 4).
- En volume, cela représente 0,85 % des unités et 1,3 % du chiffre d'affaires : 19,3 M$ en deux ans, pour 11,1 M$ de marge perdue.

## 13.2 Choisir la bonne mesure avant de comparer

Le taux de retour en unités, le plus intuitif, est trompeur. Comme un retour porte presque toujours sur une unité, ce taux est divisé par cinq entre les petites et les grosses lignes (de 1,6 % à 0,3 %) : il mesure la taille des lignes, pas la fréquence des retours.

Il aurait conduit à trois conclusions fausses : une forte amélioration en 2021, des produits chers plus retournés, et une catégorie trois fois « meilleure » que les autres. Les trois viennent de la taille des lignes.

| Question | Mesure retenue | Pourquoi |
|---|---|---|
| Qui retourne le plus souvent ? | Part des lignes avec retour | La moins sensible à la taille des lignes : c'est notre taux standardisé |
| Qu'est-ce que cela coûte ? | Taux en valeur et marge perdue | Des dollars, comparables partout |

## 13.3 Aucun facteur ne concentre les retours

| Facteur | Résultat |
|---|---|
| Catégorie, gamme, marque | Écarts d'un ou deux points. Taille d'effet négligeable (V de Cramér inférieur à 0,06) |
| Produit | Les écarts entre produits sont ceux du hasard : 16 produits sur 2 508 dépassent trois écarts-types, contre 7 attendus |
| Mois, jour, jour férié, année | Aucun effet |
| Prix | Aucun effet sur la fréquence |
| Type de boutique | Un écart réel mais modeste : 16,9 % en ligne, 12,6 % en magasin |
| Magasins entre eux | Quatre points d'écart au plus (10,5 % à 14,6 %) |

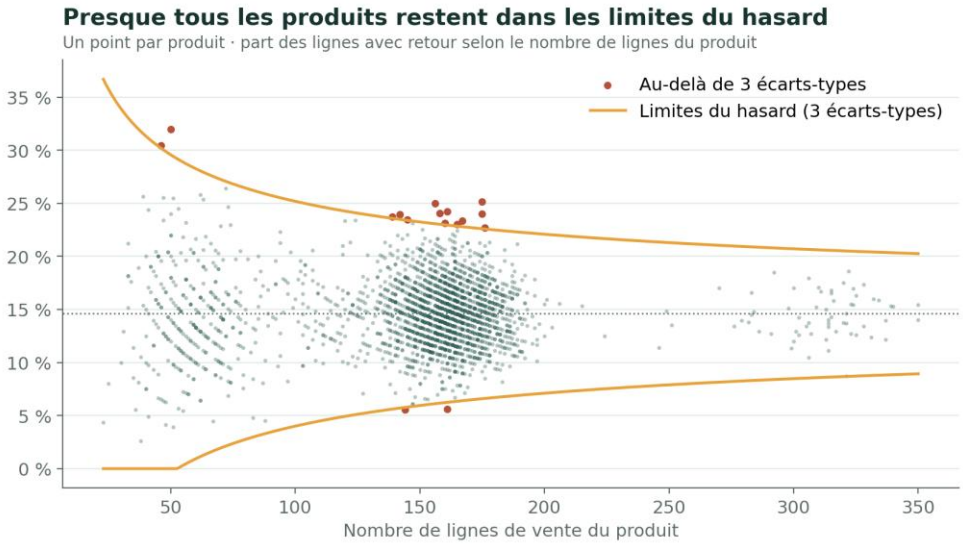



*Figure 18. Les produits se tiennent dans les limites du hasard*

**Méthode à retenir.** Un classement brut des produits par taux de retour aurait désigné de « mauvais » produits qui ne le sont pas : les plus hauts affichent 24 % à 32 % de retours, mais sur 50 à 175 lignes seulement. La comparaison à ce que donnerait le hasard évite cette erreur.

**Interprétation (hypothèse).** L'écart entre la boutique en ligne et les magasins peut s'expliquer par l'achat sans voir le produit. C'est plausible, mais non vérifiable : les données ne contiennent aucun motif de retour.

## 13.4 Ce qui varie, c'est le coût

- **Trois catégories font 81 % de la marge perdue** : Home Appliances (4,1 M$), Computers (2,8 M$) et Cameras and camcorders (2,1 M$). Une sous-catégorie se détache, Washers & Dryers, avec 13 % du total à elle seule.
- **Ce n'est pas parce qu'on y retourne davantage.** Leur fréquence de retour est ordinaire (14,7 % pour Home Appliances). Le coût s'explique par le prix de ce qui est retourné (une unité de Washers & Dryers vaut 1 725 $ en moyenne) et par le volume de ventes.
- **Le poids des retours dépend du type de boutique** : la marge perdue vaut 2 % du résultat d'exploitation en ligne et chez le revendeur, mais deux fois le résultat des magasins.

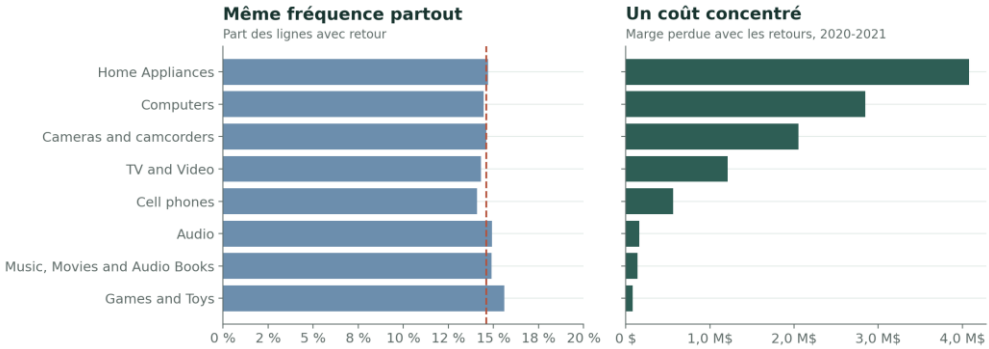



*Figure 19. Où les retours coûtent*

### 13.5 Q4 : les remises font-elles retourner davantage ?

- **Selon le taux annoncé, aucun lien** : 14,8 % de lignes avec retour sans promotion, 14,3 % à 7 %, 14,8 % à 10 %, 14,6 % à 20 %.
- **Selon que la ligne a reçu une remise, un petit écart** : 14,9 % contre 13,5 %.
- **Cet écart résiste au contrôle.** À taille de ligne, type de boutique, catégorie, gamme, mois et année identiques, une ligne remisée a un rapport de cotes de 1,10 (intervalle de 1,07 à 1,14). La probabilité de retour passe de 14,0 % à 15,2 %, soit +1,2 point.
- **L'enjeu financier est négligeable** : au plus 0,5 M$ de marge en deux ans.

### 13.6 Les retours ne se prédisent pas

Avec toutes les variables disponibles, le modèle atteint une aire sous la courbe de 0,567, à peine au-dessus du hasard (0,5). Même en connaissant tout d'une ligne, on ne peut pas dire si elle aura un retour. Un modèle plus complexe ne trouvera pas un signal qui n'existe pas. C'est pourquoi la user story du modèle prédictif des retours est close sur ce résultat.

**Réponse à Q3.** Les retours sont un bruit de fond : une ligne sur sept, une unité à la fois, partout et tout le temps, sans produit, catégorie ni période qui les concentre. Ce qui varie n'est pas leur fréquence mais leur coût, qui suit le prix des produits.

**Réponse à Q4.** Oui, une ligne remisée a un peu plus souvent un retour, d'environ un point. Le lien est solide, l'effet très faible, et sa portée financière nulle.

**Recommandations.** Ne pas faire des retours une priorité. Si une action est menée, la cibler sur le coût et non sur la fréquence (Washers & Dryers, gros appareils, ordinateurs). Ne pas durcir la politique de retour en ligne. Collecter le motif du retour, sans lequel aucune cause ne peut être établie.

## 14. Synthèse des réponses

| | Question | Réponse |
|---|---|---|
| Q1 | Facteurs déterminants de la performance des ventes | Le **produit** fixe le montant d'une ligne (89 % de la variation). Le **type de boutique** et la **période** fixent le nombre de lignes. La boutique elle-même ne compte pas. La baisse de 2021 vient de l'**usure du catalogue**. La rentabilité se joue sur les frais généraux et la publicité |
| Q2 | Effet des promotions sur le volume et la marge | **Aucun gain de ventes démontré**, indices plutôt contraires. Coût certain de 29,4 M$ en deux ans |
| Q3 | Patterns de retour | **Aucun.** Une ligne sur sept, une unité à la fois, partout et tout le temps. Seul le coût varie, avec le prix des produits |
| Q4 | Corrélation entre remises et retours | **Oui, mais négligeable** : environ un point de fréquence en plus, sans portée financière |
| Q5 | Niveaux de remise qui maximisent la marge | **Aucune remise en magasin**, où elle est un pur coût. Le niveau le plus bas ailleurs, sous réserve d'essai. Le niveau à 20 % n'est justifié nulle part |

### En quatre phrases

- Le chiffre d'affaires dépend de ce qu'on vend et de combien de fois on le vend, et la marge suit, au même taux partout.
- La baisse de 2021 vient d'un catalogue qui s'use plus vite qu'il ne se renouvelle, surtout en magasin et sur Home Appliances et Cameras.
- La rentabilité se joue après la marge : les charges ont augmenté pendant que les ventes baissaient, et la publicité absorbe le résultat des magasins.
- Les promotions et les retours, attendus comme les grands sujets, ne sont pas les leviers principaux : les premières sont à repenser, les seconds sont un bruit de fond.

### Ce que nous recommandons

- **Renouveler le catalogue**, d'abord sur Home Appliances et Cameras, et élargir l'offre vendue en magasin. Suivre chaque année l'usure du catalogue en place et l'apport des nouveautés.
- **Maîtriser les charges** : annuler la hausse de 2021, puis tenir les charges maîtrisables en proportion du chiffre d'affaires. Étudier le regroupement de l'administration et de l'informatique par pays.
- **Tester une baisse de publicité** sur une partie des magasins, en gardant les autres comme témoins, en commençant par la campagne des Fêtes dans la presse. Répartir la publicité selon le chiffre d'affaires plutôt qu'à parts égales.
- **Arrêter les remises générales en magasin** et repenser la promotion.
- **Ne pas faire des retours une priorité**, et collecter leur motif.

### Limites à garder en tête

- Le jeu de données est généré : plusieurs constats sont des propriétés du générateur et non des comportements.
- Une ligne est un cumul journalier, sans client ni ticket.
- Les prix, la publicité et le calendrier des promotions ne varient pas : leurs effets ne sont pas mesurables.
- Deux années seulement : une tendance repose sur une seule comparaison d'une année à l'autre.
- Le gain du renouvellement du catalogue est brut : le coût des lancements n'est pas dans les données.

CONCLUSION

# Ce qui change pour la suite du projet

## 15. Conclusion : mise à jour du backlog, des notebooks et suite du projet

### 15.1 Bilan

Les données sont **propres sur le plan technique** : aucun doublon, aucune clé orpheline, aucune valeur impossible, et des totaux égaux à une source indépendante au cent près. Le nettoyage est léger et entièrement tracé : sept règles, aucune ligne supprimée, aucun montant modifié, deux valeurs corrigées (une quantité sur 386 lignes, un effectif sur un magasin).

Elles sont **limitées sur le plan de la signification** : c'est un jeu généré par des règles. Une grande part du travail a été de comprendre ces règles, pour savoir quelles conclusions tiennent.

L'analyse a répondu aux cinq questions de recherche. Son résultat le plus important n'était pas attendu : les deux premiers leviers de rentabilité sont le renouvellement du catalogue et la maîtrise des charges, et non les promotions et les retours.

### 15.2 Mise à jour du backlog

Les résultats obtenus changent l'orientation du projet. Le backlog a été mis à jour le 7 octobre (version 3). Les sprints et les dates de remise ne changent pas.

| Indicateur | Version 2 | Version 3 |
|---|---|---|
| Tâches | 185 | 211 |
| Tâches terminées | 41 | 120 |
| User stories | 37 | 42, dont 17 terminées et 1 abandonnée |

| User story | Changement et raison |
|---|---|
| Prévision des ventes | Réorientée vers une prévision par l'âge du catalogue, puisque l'usure du catalogue explique la baisse. Le modèle saisonnier classique est écarté : 24 mois ne donnent que deux cycles |
| Risque de retour | Close sur un résultat négatif : le modèle ne prédit pas mieux que le hasard |
| Réponse aux promotions | **Abandonnée.** Sans groupe témoin, un modèle n'apprendrait que la saison |
| Scénarios | Deviennent prioritaires, et portent sur les leviers de rentabilité au lieu des seules promotions |
| Optimisation | Appliquée aux priorités de renouvellement par sous-catégorie, au lieu du taux de remise optimal, qu'aucune donnée ne permet d'établir |

| User story | Changement et raison |
|---|---|
| Plan promotionnel | Remplacé par un plan d'essais : plusieurs recommandations se terminent par « à tester », il faut dire comment |
| Nouvelles | Explication de la baisse de 2021, leviers de rentabilité, modèle des charges, typologie des magasins, application Streamlit |

Chaque changement est daté et justifié dans l'onglet Changements du backlog.

## 15.3 Mise à jour des notebooks

| Notebook | Changement | Raison |
|---|---|---|
| 03 | La décision sur l'effectif manquant passe de « laisser vide » à « imputer » | Nécessaire pour la suite du projet |
| 04 | Règle N7 ajoutée, quatre contrôles de validation ajoutés | Idem |
| 05b | Test ajouté : peut-on déduire l'effectif de la masse salariale ? | Justifie le choix de la règle N7 |
| 06 | Explication de la baisse de 2021, leviers de rentabilité, coût par employé calculé sans le magasin imputé | Résultat central du projet |
| 09 | Comparaison des remises par type de boutique | Le résultat d'ensemble mélangeait deux réalités opposées |

## 15.4 La suite : ce qui est prévu pour la prochaine unité

Les parties prédictive et prescriptive du projet restent à réaliser. Elles feront l'objet de la prochaine présentation et du rapport final.

| Notebook | Contenu | Ce qu'il apporte |
|---|---|---|
| 10 | Prévision des ventes par l'âge du catalogue | Ventes attendues en 2022 selon le nombre de nouveautés lancées, avec une fourchette |
| 11 | Modèle des charges | Part fixe et part variable de chaque compte, résultat attendu pour un niveau de ventes |
| 12 | Typologie des magasins | Ce qui distingue les huit magasins aux frais généraux bas des 46 autres |
| 13 | Simulateur de scénarios | Résultat d'exploitation selon les leviers actionnés, avec une grille quand l'effet sur les ventes est inconnu |
| 14 | Priorités de renouvellement | Dans quelles sous-catégories lancer des nouveautés en premier |
| 15 | Plan d'essais | Quels magasins tester, combien de temps, quelle variation on saurait détecter |

Deux tableaux de bord reprendront ces résultats, l'un dans Power BI, l'autre sous forme d'application Streamlit, avec les mêmes quatre pages : vue d'ensemble, catalogue, magasins et charges, simulateur.

**Trois précautions guideront cette suite**, toutes issues du présent diagnostic :

- **Prévoir n'est pas simuler.** Un modèle prévoira bien les ventes, parce qu'elles suivent un calendrier régulier. Il ne dira pas ce qui se passerait si l'on changeait la publicité ou les promotions, puisque ces variables ne varient pas dans les données.
- **Avec deux années, toute prévision est fragile.** Chaque prévision sera comparée à une référence naïve et donnée avec une fourchette.
- **Raisonner sur les charges de personnel, pas sur le nombre d'employés**, pour la raison établie en section 7.3.

# Annexe : fichiers produits et notebooks

## Fichiers produits par le nettoyage et les transformations

| Fichier | Contenu |
|---|---|
| `data/clean/fait_ventes.parquet` | Table propre : 376 234 lignes, 47 colonnes |
| `data/clean/fait_ventes_variables.parquet` | Table propre avec les variables dérivées : 67 colonnes |
| `data/clean/fait_charges.parquet` | Charges : 355 236 lignes, 16 colonnes |
| `data/clean/dimensions` | 9 tables : boutique, produit, promotion, canal, date, contexte, catégorie, compte, scénario |
| `data/clean/agregats` | 7 tables agrégées |
| `data/clean/journal_nettoyage.csv` | Une entrée par règle et par colonne, avec la justification |
| `data/clean/corrections_remise.csv` | Les 386 lignes de la règle N6, avec leur quantité d'origine |
| `data/clean/rapport_validation.csv` | Les 28 contrôles de validation et leur résultat |
| `diagnostic_qualite.xlsx` | Le registre des 56 contrôles du diagnostic et ses tableaux de détail |

## Notebooks de préparation

| Notebook | Rôle |
|---|---|
| `00_inventaire` | Inventaire des fichiers et des tables, vérification du décalage de douze ans, justification du périmètre |
| `01_etl` | Chargement, conversion des types, consolidation des huit trimestres |
| `02_flocon` | Réalignement des dates, dimensions, calendrier, contexte, jointure aux ventes |
| `03_diagnostic` | Les 56 contrôles de qualité, sans aucune modification |
| `04_nettoyage` | Les sept règles, le journal et la validation |
| `05_variables` | Variables dérivées et tables agrégées |
| `05b_charges` | Intégration du plan stratégique, table commune ventes et charges |

## Notebooks d'analyse et classeurs de résultats

| Notebook | Rôle | Classeur de résultats |
|---|---|---|
| `06_q1_performance` | Facteurs de vente, usure du catalogue, rentabilité après charges, leviers | `q1_tableaux.xlsx` (51 feuilles) |
| `07_q2_promotions` | Effet des promotions : trois angles, coût et seuils | `q2_tableaux.xlsx` (17 feuilles) |
| `08_q3_q4_retours` | Patterns de retour, lien avec les remises, coût | `q3_q4_tableaux.xlsx` (30 feuilles) |
| `09_q5_remises` | Niveaux de remise et marge, par type de boutique | `q5_tableaux.xlsx` (12 feuilles) |